

Universidad de Ibagué

Facultad de Ingeniería

Asignatura: Inteligencia Artificial

**Predicción de Riesgo Financiero en
PYMES Colombianas mediante
Machine Learning con Datos del
SIREM (2016–2024)**

Trabajo final

Autores

Juan Camilo Perea

German

2026

Resumen

El presente trabajo desarrolla y evalúa un modelo de *Machine Learning* supervisado para clasificar el riesgo financiero de PYMES colombianas en tres niveles (bajo, medio y alto) a partir de sus estados financieros bajo NIIF reportados al Sistema de Información y Reporte Empresarial (SIREM) de la Superintendencia de Sociedades. El conjunto de datos comprende 38 245 PYMES y 203 104 observaciones empresa-año entre 2016 y 2024. La metodología integra (i) el cálculo de 18 indicadores financieros y el Z''-Score de Altman; (ii) la construcción de un *ground truth* triangulado mediante terciles empíricos del Z-Score y reglas heurísticas de consenso; (iii) la ingeniería de 71 características con términos temporales interanuales; (iv) una partición cronológica estricta (2016–2021 / 2022 / 2023–2024) con *holdout* regional de Ibagué (61 PYMES, 359 observaciones); y (v) la comparación de cuatro modelos — regresión logística, Random Forest, XGBoost y XGBoost+SMOTE — evaluados sobre 50 957 observaciones de prueba. El modelo XGBoost (`max_depth=8`, `learning_rate=0,1`) obtuvo $F1\text{-macro} = 0,997$ y $AUC\text{-ROC OvR macro} \approx 1,0$ sobre el conjunto de prueba nacional, y $F1\text{-macro} = 0,995$ sobre el holdout de Ibagué con un único error de clasificación en 359 predicciones. La interpretación con TreeSHAP identifica al Z''-Score, el margen neto y la razón corriente como las características dominantes, en línea con la literatura. El modelo supera a la heurística Altman pura por +56 puntos porcentuales en F1-macro, validando la contribución marginal del *Machine Learning* sobre los métodos clásicos.

Palabras clave: *Machine Learning*; riesgo financiero; PYMES; XGBoost; TreeSHAP; NIIF; SIREM.

Abstract

This work develops and evaluates a supervised *Machine Learning* model to classify the financial risk of Colombian SMEs into three levels (low, medium and high) using IFRS financial statements reported to the Sistema de Información y Reporte Empresarial (SIREM) operated by the Superintendencia de Sociedades. The dataset comprises 38,245 SMEs and 203,104 firm-year observations from 2016 to 2024. The methodology integrates 18 financial ratios plus Altman’s Z''-Score, a triangulated ground truth combining empirical Z-Score terciles and heuristic consensus rules, 71 engineered features with year-over-year terms, a strict chronological train/validation/test split (2016–2021 / 2022 / 2023–2024), and a regional holdout of 61 SMEs from Ibagué (359 observations). XGBoost (`max_depth=8`, `learning_rate=0.1`) achieves $F1\text{-macro} = 0,997$ and OvR-macro AUC-ROC $\approx 1,0$ on a 50,957-sample national

test set, and F1-macro = 0,995 on the Ibagué holdout with only one misclassification out of 359 predictions. TreeSHAP interpretation identifies the Z''-Score, net margin and current ratio as the dominant features. The model outperforms the pure Altman heuristic by +56 percentage points in F1-macro, demonstrating substantial marginal value of *Machine Learning* over classical methods.

Keywords: *Machine Learning*; financial risk; SMEs; XGBoost; TreeSHAP; IFRS; SIREM.

1. Introducción

1.1. Ubicación del problema

Las pequeñas y medianas empresas (PYMES) son el motor del tejido productivo colombiano: representan más del 90 % del total de unidades empresariales formales y generan una proporción crítica del empleo nacional, pero exhiben tasas de mortalidad temprana significativas y un acceso limitado a financiación (Higuera-Vargas and Contreras-Cáceres, 2021). La evidencia cualitativa de Cardona Zuleta and Castro Álvarez (2025) en Medellín revela además una brecha cognitiva: muchos directivos de PYMES desconocen el concepto operativo de riesgo financiero y, consecuentemente, no incorporan diagnósticos sistemáticos en sus decisiones. Este desfase entre la disponibilidad de datos contables estandarizados bajo NIIF y su aprovechamiento analítico constituye un área pertinente para el desarrollo de herramientas reproducibles de soporte a la decisión.

Desde la década de 1960 los modelos clásicos de predicción de quiebra —Altman (1968), Ohlson (1980), Zmijewski (1984)— proporcionaron un marco conceptual influyente, pero su precisión se degrada significativamente fuera del contexto en el que fueron calibrados (Bouwmeester, 2020; Grice and Dugan, 2003; Qiu et al., 2020). La adopción contemporánea del *Machine Learning* (ML), particularmente los métodos de ensamble basados en árboles, ofrece una vía para modelar relaciones no lineales en datos contables tabulares y ha demostrado consistentemente superioridad sobre los métodos estadísticos clásicos (Chen and Guestrin, 2016; Dasilas and Rigani, 2024). Sin embargo, la literatura empírica latinoamericana sobre predicción de riesgo en PYMES sigue siendo escasa: el análisis bibliométrico de Abubakar et al. (2025) identificó solo 19 estudios específicos publicados en una década, con concentración en Asia, Europa y Estados Unidos. Colombia está particularmente subrepresentada, pese a contar con el SIREM —una fuente pública de estados financieros NIIF a escala nacional— como insumo potencial.

El presente trabajo aborda esta brecha desarrollando un modelo XGBoost interpretable mediante TreeSHAP entrenado sobre 38 245 PYMES y 203 104 observaciones empresa-año del SIREM, con validación regional sobre el subconjunto de Ibagué identificado mediante cruce con la Cámara de Comercio.

1.2. Estado del arte: síntesis condensada

La revisión completa del estado del arte se presenta en el documento *Estado del Arte v2*; aquí se condensan los hallazgos relevantes para fundamentar el diseño metodológico de este

trabajo, organizados en siete ejes temáticos.

Riesgo financiero en PYMES. [Cultrera and Brédart \(2016\)](#) y [Kotaskova et al. \(2020\)](#) documentan los determinantes financieros de la vulnerabilidad PYME en mercados desarrollados y emergentes. [Senaya \(2025\)](#) y [Papadouli et al. \(2024\)](#) muestran la persistencia del problema en geografías diversas.

Modelos clásicos. El modelo de [Altman \(1968\)](#) y sus extensiones (Z'-Score y Z''-Score para mercados emergentes) constituyen referencias fundacionales. [Grice and Dugan \(2003\)](#) reportan caídas de precisión hasta del 60 % al transferir Ohlson fuera de su contexto original. [Bouwmeester \(2020\)](#) confirman degradación temporal en datos europeos contemporáneos. [Qiu et al. \(2020\)](#) demuestran vía análisis topológico que el espacio del Z-Score no separa limpiamente quiebras y no-quiebras.

Machine Learning para riesgo financiero. La revisión sistemática más completa, [Dasilas and Rigani \(2024\)](#) (207 estudios PRISMA), reporta a XGBoost ([Chen and Guestrin, 2016](#)) como el modelo dominante con AUC promedio de 89 %. [Boumhidi and Marghich \(2025\)](#) (PYMES marroquíes, AUC = 0,93), [Mahesh et al. \(2025\)](#) (PYMES indias, precisión 92,7 %), [Yufenyuy et al. \(2024\)](#) (32 581 obs., precisión 93,4 %) y [Bortolotti and Curi \(2024\)](#) (PYMES italianas) confirman la superioridad del ensamble. [Sujatha et al. \(2025\)](#) demuestran paridad entre XGBoost, LightGBM y CatBoost; [Wu et al. \(2022\)](#) validan híbridos Z-Score + ML. [Sun et al. \(2020\)](#) y [Kristanti et al. \(2025\)](#) establecen buenas prácticas de SMOTE dentro del split de entrenamiento.

Sistemas web e integración. [Mayorga Lira et al. \(2023\)](#) desarrollaron el único prototipo académico latinoamericano identificado (cooperativa peruana). [Ioannou and Wójcik \(2022\)](#) muestran que el sector FinTech regional concentra su actividad en capitales metropolitanas, dejando desatendidas las ciudades intermedias. La integración operativa en una interfaz web queda como trabajo futuro de la presente investigación.

Contexto NIIF colombiano. El Decreto Anexo 2 de 2015 ([Departamento Administrativo de la Función Pública, 2015](#)) adoptó las NIIF para PYMES Grupo 2 con vigencia desde 2016, alineando el SIREM con estándares internacionales. [Bubb \(2024\)](#) documenta seis cambios técnicos para 2025. El sesgo de selección del SIREM —empresas con capacidad de reporte formal— requiere reconocimiento explícito ([Zhang and Zhang, 2026](#)).

Interpretabilidad (XAI). [Bussmann et al. \(2020\)](#) demuestran que XGBoost + Shapley sobre 15 045 PYMES europeas combina alto AUROC (0,93) con interpretabilidad. [Pathi and Pothineni \(2025\)](#) comparan SHAP y LIME, encontrando mayor consistencia en SHAP.

Lundberg et al. (2020) introducen TreeSHAP con tiempos polinómicos compatibles con producción. Lin and Wang (2024) reportan estabilidad de los *rankings* SHAP para variables de alta importancia. Deng et al. (2024) comparan empíricamente Shapley exacto, KernelSHAP, TreeSHAP y LIME.

Datos de panel y validación temporal. Zhou et al. (2022) y Otsuki et al. (2022) demuestran el valor predictivo del análisis temporal. Wang et al. (2024) taxonomizan datasets públicos (sin incluir el SIREM). La validación cronológica estricta es requisito metodológico para evitar fuga de información.

1.3. Justificación

La revisión de la literatura (Sección 1.2) revela seis vacíos convergentes que justifican el presente trabajo: (1) **escala muestral limitada** —la mayoría de los estudios opera con 124–806 empresas, mientras que el SIREM proporciona acceso a 38 245 PYMES; (2) **subrepresentación de América Latina** —la investigación se concentra en Asia, Europa y Estados Unidos; (3) **ausencia de datasets bajo NIIF** —ningún estudio de ML revisado tematiza explícitamente las normas internacionales como marco metodológico; (4) **insuficiente integración temporal** —predominio de cortes transversales sobre datos de panel; (5) **escasa interpretabilidad en LATAM** —ningún estudio de XAI aplicado a riesgo financiero en PYMES latinoamericanas; y (6) **degradación documentada de los métodos clásicos** —justificando la transición al ML supervisado.

1.4. Objetivos

Objetivo general

Diseñar e implementar un modelo de *Machine Learning* supervisado que clasifique el nivel de riesgo financiero (bajo, medio y alto) de PYMES colombianas a partir de sus estados financieros NIIF, y validar su comportamiento sobre las PYMES de Ibagué como caso de estudio.

Objetivos específicos

1. Calcular un conjunto reproducible de 18 indicadores financieros sobre el universo SIREM 2016–2024.
2. Construir una etiqueta de riesgo triangulada (Z'' -Score de Altman + reglas heurísticas) que sirva como *ground truth* supervisado.

3. Entrenar y comparar tres modelos: regresión logística (*baseline*), Random Forest y XGBoost.
4. Evaluar el desempeño con métricas robustas al desbalance (F1-macro, AUC-PR) y validación temporal estricta.
5. Interpretar las predicciones del mejor modelo vía TreeSHAP, identificando los factores de decisión globales y locales.
6. Validar el modelo entrenado nacionalmente sobre el subconjunto de PYMES de Ibagué y discutir sus limitaciones.

2. Metodología

El trabajo sigue una metodología cuantitativa con un *pipeline* reproducible de ocho fases técnicas, diseñado bajo los principios de validación cronológica estricta, interpretabilidad y reconocimiento explícito del sesgo de selección.

Fase 1 — Indicadores y EDA. A partir del consolidado SIREM, se calculan 18 indicadores financieros que cubren liquidez (razón corriente, prueba ácida, capital de trabajo, razón de efectivo), rentabilidad (márgenes bruto, operacional y neto, ROA, ROE), endeudamiento (razón de deuda, deuda-patrimonio, apalancamiento, cobertura de intereses) y actividad (rotación de activos, inventarios y cartera, días de inventario y cartera). Adicionalmente se computa el Z''-Score de Altman para mercados emergentes.

Fase 2 — Etiquetado. En ausencia de un registro universal de eventos reales de quiebra, se construye un *ground truth* mediante triangulación de tres señales: **etiqueta A** — zonas Altman por umbrales originales (1,1 / 2,6); **etiqueta B** — terciles empíricos del Z''-Score sobre el dataset; **etiqueta C** — reglas heurísticas de consenso basadas en cinco señales binarias por clase, calibradas con terciles empíricos por indicador. La *etiqueta final* adopta el consenso $B \equiv C$ (asignando *riesgo medio* cuando ambas discrepan), produciendo Cohen $\kappa_{B,C} = 0,446$.

Fase 3 — Ingeniería de características. Se generan 71 *features* agrupadas en siete familias: 18 indicadores base, el Z''-Score, 18 variaciones interanuales (*_d1*), 6 tasas de crecimiento multi-año (*_g2*, *_g3*), 4 variables de escala/estructura (logaritmos de activos e ingresos, ratios de balance), 2 variables temporales (año numérico, dummy COVID 2020) y 22 *dummies* categóricas (CIIU, tipo societario, departamento). Se aplica winsorización p1–p99 sobre 51 columnas continuas.

Fase 4 — Partición temporal. Se reserva el subconjunto de 61 PYMES de Ibagué identificadas mediante cruce con la Cámara de Comercio como *holdout* regional. El resto del SIREM se divide cronológicamente: *train* 2016–2021 (108 522 obs.), *validation* 2022 (26 878 obs.) y *test* 2023–2024 (50 957 obs.). Se excluye el año fiscal 2017 del split nacional debido a una anomalía documentada de captura del SIREM (99 % de valores nulos en Z-Score). Se verifican *asserts* de no-fuga: ninguna empresa de Ibagué aparece en los splits nacionales.

Fase 5 — Modelado. Se entrenan cuatro modelos sobre el conjunto de *train* con búsqueda en cuadrícula sobre el conjunto de *validation*: (i) regresión logística con `class_weight=balanced` como *baseline* lineal; (ii) Random Forest; (iii) XGBoost con *sample_weight* balanceado; y (iv) XGBoost con SMOTE aplicado dentro del *pipeline* de entrenamiento. La selección de hiperparámetros maximiza F1-macro en *validation*.

Fase 6 — Evaluación e interpretabilidad. El mejor modelo se evalúa sobre *test* mediante F1-macro, AUC-ROC OvR macro, AUC-PR macro, matriz de confusión y curvas ROC/PR por clase. La interpretación global se realiza con TreeSHAP (Lundberg et al., 2020) sobre 5 000 observaciones estratificadas: *beeswarm*, gráfico de barras de importancia y nueve *waterfalls* locales (uno por clase verdadera (E) clase predicha).

Fase 7 — Validación Ibagué. El modelo entrenado nacionalmente se aplica al *holdout* de Ibagué. Se reportan F1-macro y AUC-ROC desglosados por año y se documentan individualmente los errores de clasificación con justificación financiera.

Fase 8 — Discusión comparativa. Se compara el desempeño contra (i) la heurística de Altman pura (umbrales originales y terciles empíricos); (ii) un *golden standard* construido por etiquetado manual experto sobre 30 PYMES de Ibagué con protocolo declarado a-priori; (iii) la literatura del estado del arte; y (iv) tres pruebas de robustez: estabilidad temporal, sectorial y de los *rankings* SHAP sobre cinco semillas aleatorias.

Reproducibilidad. Todo el código se encuentra en notebooks Jupyter numerados 03–10 con `random_state = 42` y `np.random.seed(42)` en cada celda inicial. Los modelos se serializan con `joblib`. La carga del consolidado SIREM se realiza siempre vía `src.etl_utils.cargar_consolidado()` que aplica la normalización de *mojibake* en 105 columnas afectadas por re-codificación Latin-1→UTF-8.

3. Materiales

3.1. Fuente de datos: SIREM

El Sistema de Información y Reporte Empresarial (SIREM) de la Superintendencia de Sociedades de Colombia publica los estados financieros bajo NIIF de las empresas vigiladas. Para este trabajo se descargaron cuatro datasets en formato CSV vertical (una fila por concepto-valor) cubriendo los ejercicios fiscales 2016–2024:

1. **Carátula** (2,07 GB) — metadatos de empresa.
2. **Estado de Situación Financiera** (4,10 GB) — balance.
3. **Estado de Resultado Integral** (1,57 GB) — estado de resultados.
4. **Estado de Flujo de Efectivo** (1,43 GB) — flujos de efectivo.

Tras el ETL —ejecutado en los notebooks `01_etl_camara_comercio.ipynb` y `02_etl_nacional_pymes.ipynb` previos a las fases reportadas en este documento— se obtiene un consolidado de 203 104 filas $\times$ 230 columnas (2 identificadores + 24 metadatos + 204 conceptos contables) tras pivotar los datos verticales. El filtro `PUNTO_ENTRADA  $\supset$  "Pymes"` aisló el subconjunto NIIF Pymes Grupo 2.

3.2. Subconjunto de Ibagué (caso de estudio)

La Cámara de Comercio de Ibagué proporcionó 66 NITs de PYMES locales. El cruce con el SIREM (notebook 01) tras limpieza de NITs —el SIREM almacena formato con comas ("900,152,104") y la CCI usa 10 dígitos con dígito de verificación, mientras el SIREM usa 9 dígitos— recuperó 61 empresas presentes en NIIF Pymes (los 5 NITs ausentes pertenecían a NIIF Plenas o categoría "No aplica" filtradas previamente). El subconjunto comprende 359 observaciones empresa-año que constituyen el *holdout* regional.

3.3. Distribución por partición

La Tabla 1 resume la distribución de la etiqueta de riesgo a través de los cuatro splits.

3.4. Herramientas

El *stack* técnico consiste en Python con `pandas` para manipulación de datos, `scikit-learn` para los modelos clásicos y la regresión logística, `xgboost` para el ensamble basado en árboles con soporte GPU, `imbalanced-learn` para SMOTE, y `shap` para la interpretación con

Tabla 1: Distribucion de etiqueta de riesgo por split (Fase 4). El holdout Ibague incluye 2017; los splits nacionales lo excluyen por incompletitud del SIREM 2017.

Clase	Train		Val		Test		Ibague	
	N	%	N	%	N	%	N	%
Alto	21 241	19.57 %	4 413	16.42 %	8 403	16.49 %	64	17.83 %
Medio	69 335	63.89 %	17 160	63.84 %	31 831	62.47 %	257	71.59 %
Bajo	17 946	16.54 %	5 305	19.74 %	10 723	21.04 %	38	10.58 %
Total	108 522	100.00 %	26 878	100.00 %	50 957	100.00 %	359	100.00 %

TreeSHAP. Las figuras se generan con `matplotlib` a 300 DPI. El cuaderno de modelado XGBoost ejecutó en GPU NVIDIA RTX 2060 con `device='cuda'`, obteniendo un *speedup* de aproximadamente $4\times$ sobre la ejecución en CPU. El entorno Python usa la versión 3.14 con dependencias sin pinear.

4. Desarrollo

4.1. Cálculo de indicadores y exploración (Fase 1)

Sobre el consolidado SIREM se aplicó `calcular_todos(df)` produciendo `colombia_indicadores_pymes.c` ($203\,104 \times 23$). La completitud por indicador (Figura 1) osciló entre 54,8% en *días de inventario* (denominador frecuentemente nulo en empresas sin inventario significativo) y 95,2% en *rotación de cartera*. Ningún indicador presentó 100% de nulos.




Figura 1: Completitud por indicador financiero sobre el universo SIREM 2016–2024 (203 104 observaciones empresa-año).

La distribución del Z"-Score (Figura 2) es unimodal con cola pesada hacia valores altos y mediana de 4,93. Esta distribución motivó el uso de terciles empíricos en lugar de los umbrales originales 1,1 / 2,6 calibrados para mercados estadounidenses, los cuales producirían un sobre-etiquetado del 65,9% de las observaciones como *riesgo bajo*.




Figura 2: Distribución empírica del Z'-Score sobre el SIREM. Líneas verticales: umbrales Altman originales (1,1 y 2,6) y percentiles 33 y 66 empíricos.

4.2. Etiquetado triangulado (Fase 2)

Se evaluaron tres etiquetadores: A (umbrales Altman originales), B (terciles empíricos del Z-Score) y C (reglas heurísticas con terciles por indicador). Las concordancias *pairwise* produjeron $\kappa_{A,B} = 0,234$, $\kappa_{A,C} = 0,203$ y $\kappa_{B,C} = 0,446$. La etiqueta A se descartó por baja concordancia y sesgo de calibración. La heurística original del plan de trabajo (umbrales fijos: margen < 0 , razón corriente < 1 , etc.) producía $\kappa_{B,C} = 0,304$, por debajo del umbral 0,4 establecido como criterio de aceptación; reemplazar los umbrales fijos por terciles empíricos por indicador permitió alcanzar $\kappa_{B,C} = 0,446 \geq 0,4$, cumpliendo el criterio.

La distribución de la *etiqueta final* (consenso $B \equiv C$, con asignación *riesgo medio* en discrepancia) es 16,8 % bajo / 66,4 % medio / 16,8 % alto, satisfaciendo la condición de mínimo 5 % por clase. La Figura 3 presenta el *heatmap* de concordancia $B \times C$, y la Figura 4 muestra la evolución temporal: contrariamente a la hipótesis inicial, el año 2020 no exhibe deterioro relativo respecto a 2019 ($\Delta = -0,11$ pp), un hallazgo discutido en la Sección 6.




Figura 3: Heatmap de concordancia entre etiquetadores B (terciles del Z'' -Score) y C (reglas heurísticas). Cohen $\kappa_{B,C} = 0,446$.



Figura 4: Distribución porcentual de la etiqueta final por año fiscal.

4.3. Ingeniería de características (Fase 3)

El *dataset* de modelado `colombia_features_ml.csv` ($203\,104 \times 77$) contiene 71 *features* para ML más 3 columnas categóricas de diagnóstico (sector, sociedad, departamento en texto) y 3 IDs. La Tabla 2 resume la composición por familia.

Tabla 2: Familias de características en el dataset de modelado.

Familia	Descripcion	Numero
Indicadores financieros base	<i>razon_corriente</i> , ROA, ...	18
Z"-Score Altman	Score continuo de bancarrota	1
Variaciones interanuales	$(x_t - x_{t-1})/ x_{t-1} $ por indicador	18
Crecimientos 2 y 3 años	roa, margen_neto, razon_deuda	6
Escala y estructura	log activos, log ingresos, ratios corrientes	4
Temporales	año numerico, dummy COVID 2020	2
Dummies categoricas	CIU(12), sociedad(4), depto(6)	22
Total		71

Tres criterios fueron verificados: (i) cero columnas con 100 % de valores nulos; (ii) cero duplicados (NIT, AÑO); (iii) los tres grupos de *dummies* (CIU 12, sociedad 4, departamento 6) suman exactamente 1 en las 203 104 filas. La completitud peor caso de los *features* nuevos es de aproximadamente 43 % (`dias_inventario_d1`, `rotacion_inventarios_d1`, `roa_g3`, `razon_deuda_g3`); el promedio de los 28 *features* nuevos es del 64 %.

4.4. Partición temporal y holdout (Fase 4)

El split temporal produjo train 108 522 / val 26 878 / test 50 957 / holdout Ibagué 359 observaciones empresa-año. Los cuatro *asserts* de no-fuga (los 61 NITs de Ibagué ausentes en cada split nacional + cobertura completa de NITs nacionales) pasaron exitosamente. La Figura 5 ilustra la distribución de clases por split.




Figura 5: Distribución de la etiqueta final de riesgo por split (train / val / test / Ibagué holdout).

El delta máximo entre splits es de 4,5 pp en la clase *riesgo bajo* (train vs. test), por debajo del umbral ≤ 5 pp del criterio de aceptación. Se observa un *drift* sutil de etiqueta hacia *riesgo bajo* en 2023–2024 (de 16,5 % en train a 21,0 % en test), coherente con la recuperación macroeconómica post-COVID.

4.5. Modelado (Fase 5)

Los hiperparámetros ganadores (mejor F1-macro en *validation* 2022) fueron:

- **Regresión logística:** C=10; F1-macro val = 0,799.
- **Random Forest:** n_estimators=500, max_depth=None, min_samples_split=10; F1-macro val = 0,995.
- **XGBoost** (*sample_weight*): max_depth=8, learning_rate=0,1, subsample=0,8, colsample_bytree=0,8, best_iteration=221 bajo early_stopping_rounds=30; F1-macro val = 0,9979.
- **XGBoost+SMOTE:** max_depth=4, learning_rate=0,05; F1-macro val = 0,9957.

El modelo seleccionado es XGBoost (*sample_weight*), con un *gap* train→val de +0,21 pp (sin sobreajuste detectable). La búsqueda total comprendió $4 + 18 + 24 + 24 = 70$ *fits*; en GPU el cuaderno completo corrió en aproximadamente 14 minutos.

4.6. Evaluación, SHAP y validación Ibagué (Fases 6 y 7)

Los resultados detallados de las Fases 6 y 7 se reportan en la Sección 5 para mantener separadas las decisiones metodológicas (este desarrollo) de la presentación de métricas.

5. Resultados

5.1. Comparativa entre modelos sobre validación y test

La Tabla 3 resume el desempeño de los cuatro modelos sobre el conjunto de validación 2022. La Tabla 4 reporta los mismos modelos sobre el conjunto de prueba 2023–2024 ($n = 50\,957$). La Figura 6 muestra gráficamente la comparación.

Tabla 3: Comparacion de los cuatro modelos sobre el conjunto de validacion (2022). F1-macro en train y val + gap en puntos porcentuales (PLAN 5.3 exige gap <10pp). Mejor XGBoost vs LR baseline en val: +19.86pp.

Modelo	F1 train	F1 val	gap (pp)
XGBoost	1.0000	0.9979	+0.21
XGBoost+SMOTE	0.9998	0.9957	+0.41
RandomForest	0.9999	0.9948	+0.51
LogisticRegression	0.8074	0.7993	+0.81

Tabla 4: Metricas globales sobre el conjunto de test nacional (2023–2024, $n = 50\,957$). Mejor modelo: xgboost.

Modelo	Acc	F1-macro	F1-pond	AUC-ROC _{OvR}	AUC-PR _{macro}
xgboost	0.9975	0.9972	0.9975	1.0000	1.0000
xgboost smote	0.9962	0.9956	0.9962	1.0000	0.9999
random forest	0.9950	0.9943	0.9950	0.9999	0.9998
logistic regression	0.8210	0.8105	0.8239	0.9533	0.8932




Figura 6: Comparación de F1-macro de los cuatro modelos en train, validación y test. XGBoost (*sample_weight*) es el modelo seleccionado.

El mejor modelo en test es **XGBoost** con F1-macro = 0,9972, AUC-ROC OvR macro = 0,99999 y AUC-PR macro = 0,99997. La ventaja sobre el *baseline* logístico es de +19,86

pp en validación y +18,67 pp en test, satisfaciendo el criterio del plan de superar al *baseline* por al menos 5 pp.

No se observa *drift* entre splits: train $\rightarrow$ val $\rightarrow$ test = 1,0000 $\rightarrow$ 0,9979 $\rightarrow$ 0,9972 para XGBoost, con *gap* test–val de $-0,07$ pp. La regresión logística incluso sube ligeramente en test (+1,12 pp), sin señales de degradación.

5.2. Matriz de confusión y curvas ROC/PR

La Figura 7 presenta la matriz de confusión de XGBoost sobre test. Los *recall* por clase son: *riesgo alto* 99,85 % ($n = 8\,403$), *riesgo bajo* 99,53 % ($n = 10\,723$) y *riesgo medio* 99,80 % ($n = 31\,831$). El total de errores es 127 sobre 50 957 observaciones (0,25 %), concentrados en las fronteras alto $\leftrightarrow$ medio y bajo $\leftrightarrow$ medio (zona gris natural del etiquetado triangulado). Las curvas ROC y precision-recall por clase (Figura 8) confirman la separabilidad efectiva: las tres curvas ROC se aproximan al ángulo superior izquierdo y las tres curvas PR al ángulo superior derecho.




Figura 7: Matriz de confusión del modelo XGBoost sobre el conjunto de test 2023–2024 ($n = 50\,957$). Errores totales: 127 (0,25 %).




Figura 8: Curvas ROC (izquierda) y precision-recall (derecha) por clase para XGBoost sobre el conjunto de test. AUC-ROC OvR macro = 0,99999.

5.3. Interpretación TreeSHAP

La interpretabilidad global se obtuvo aplicando TreeSHAP sobre 5 000 observaciones estratificadas del conjunto de test. La Figura 9 muestra el gráfico *beeswarm* y la Figura 10 la importancia agregada por $mean(|SHAP|)$.




Figura 9: TreeSHAP *beeswarm* sobre 5 000 observaciones estratificadas de test. El Z''-Score domina la decisión, seguido por el margen neto y la razón corriente.




Figura 10: Importancia global por $\text{mean}(|\text{SHAP}|)$ para el modelo XGBoost. Top 10 *features*.

El *ranking* de $\text{mean}(|\text{SHAP}|)$ es: (1) `z_score_altman` (3,16), (2) `margen_neto` (1,05), (3) `razon_corriente` (1,02), (4) `cobertura_intereses` (0,95), (5) `razon_deuda` (0,72), (6) `roa` (0,55), (7) `capital_trabajo` (0,27), (8) `deuda_patrimonio` (0,18), (9) `roe` (0,08) y (10) `apalancamiento` (0,06). El Z'-Score pesa aproximadamente $3\times$ más que el segundo *feature*, reflejando que el etiquetado triangulado utiliza ese mismo Z-Score como una de las dos señales del consenso $B \equiv C$; este punto se discute en detalle en la Sección 6.

Siete de las nueve *features* esperadas según la síntesis del estado del arte —`cobertura_intereses`, `razon_deuda`, `margen_neto`, `roa`, `razon_corriente`, `capital_trabajo` y `z_score_altman`— aparecen en el top 10 SHAP, evidenciando consistencia con la literatura.

La Figura 11 presenta nueve *waterfall plots* locales (uno por celda de la matriz clase verdadera $\times$ clase predicha), permitiendo trazar el aporte de cada *feature* en predicciones individuales.

etiquetado nivel-base no observa pero el modelo sí capta. Los años 2016–2023 produjeron $F1\text{-macro} = 1,0000$; solo 2024 bajó a 0,9640 por el único error.

La Figura 12 presenta la matriz de confusión de Ibagué, y la Figura 13 traza la evolución temporal de cinco PYMES con cobertura de los 9 años del panel.




Figura 12: Matriz de confusión de XGBoost sobre el holdout de Ibagué ($n = 359$). Un solo error en 2024.




Figura 13: Evolución temporal de la clasificación de riesgo (real vs. predicho) para cinco PYMES de Ibagué con cobertura completa de 9 años.

6. Discusión

6.1. Comparación contra métodos clásicos

La Tabla 6 compara los cuatro modelos de ML contra dos versiones de la heurística de Altman: *umbrales originales* (1,1 / 2,6) y *terciles empíricos* calibrados sobre el dataset.

La Figura 14 grafica la comparativa.

Tabla 6: Comparacion de metodos sobre test nacional ($n = 50\,957$, 2023–2024). XGBoost supera a Altman puro (umbrales originales) por +56.01pp en F1-macro – validando que el modelo aprende patrones que la heuristica no captura. La columna AUC-ROC para Altman/heurísticas se reporta con pseudo-probabilidades one-hot derivadas de la etiqueta dura.

Metodo	Acc	F1-macro	F1-pond	AUC-ROC _{OvR}
XGBoost	0.9975	0.9972	0.9975	1.0000
XGBoost+SMOTE	0.9962	0.9956	0.9962	1.0000
RandomForest	0.9950	0.9943	0.9950	0.9999
LogisticRegression	0.8210	0.8105	0.8239	0.9533
Altman terciles	0.6867	0.6891	0.6844	0.8411
Altman umbrales originales	0.3793	0.4371	0.3168	0.6478




Figura 14: Comparación de F1-macro entre XGBoost y los métodos clásicos sobre el conjunto de test nacional ($n = 50\,957$). XGBoost supera a Altman puro por +56,0 pp.

El resultado clave es que **XGBoost supera a Altman puro por +56,0 pp** en F1-macro (0,997 vs. 0,437) y por +30,8 pp respecto a Altman terciles (0,997 vs. 0,689). La heurística original de Altman —calibrada para empresas estadounidenses cotizadas en bolsa— funciona muy mal sobre PYMES colombianas bajo NIIF, en línea con la degradación temporal y geográfica reportada por [Grice and Dugan \(2003\)](#) y [Bouwmeester \(2020\)](#). Los terciles empíricos mejoran sustancialmente pero siguen muy por debajo del ML, demostrando que XGBoost aprende patrones de interacción entre las 71 *features* que la regla univariante Z-Score no puede capturar.

Esta diferencia de +30,8 pp respecto a la heurística del Z-Score calibrada empíricamente

cuantifica la **contribución marginal del Machine Learning** sobre la heurística de etiquetado y atiende directamente la primera mitigación declarada en el estado del arte (§ 2.3 de la versión v2): el modelo no se limita a replicar la regla heurística, sino que extrae valor predictivo adicional del espacio extendido de *features* que incluye variaciones interanuales, crecimientos plurianuales, escala empresarial y dummies categóricas.

6.2. Comparación contra etiquetado manual experto (golden standard)

Sobre 30 PYMES de Ibagué (10 por clase predicha por XGBoost) se aplicó un protocolo de etiquetado manual reproducible declarado a-priori, basado en el Z'-Score como punto de partida y cuatro ajustes (liquidez, solvencia, operativa y *shock* interanual). La Tabla 7 presenta los acuerdos.

Tabla 7: Acuerdo entre el modelo XGBoost, el etiquetado manual experto (protocolo Z-Score + ajustes, $n = 30$) y la etiqueta de Fase 2 (consenso B $\equiv$ C). El acuerdo XGBoost-manual con kappa ≥ 0.5 cumple el criterio 8.3.2.

Comparacion	Coincidencias	Accuracy	Cohen κ
XGBoost vs manual	20/30	0.6667	0.5000
XGBoost vs etiqueta_final (Fase 2)	30/30	1.0000	1.0000
Manual vs etiqueta_final (Fase 2)	20/30	0.6667	0.5000

El **Cohen κ XGBoost vs. manual = 0,500** satisface el criterio del plan ($\geq 0,5$). Por construcción, κ XGBoost vs. etiqueta_final (Fase 2) = 1,0 porque XGBoost reproduce esa etiqueta con error 0,25 %. El acuerdo κ manual vs. etiqueta_final = 0,5 confirma que el protocolo manual —por diseño más extremista, gatilla *riesgo medio* solo cuando hay un ajuste sobre *bajo* o *alto*— diverge tanto de la heurística de Fase 2 como del modelo. La distribución manual fue 18 bajo / 4 medio / 8 alto frente a la distribución equilibrada de XGBoost (10/10/10), reflejando que el modelo sobre-asigna *riesgo medio* en zonas saludables relativas al protocolo manual experto. Este sesgo conservador hacia la categoría central es metodológicamente preferible al falso negativo en zonas de alto riesgo.

6.3. Comparación con la literatura

La Tabla 8 sitúa los resultados respecto al estado del arte.

Las métricas de este trabajo se ubican en el rango superior reportado en la literatura, comparables o levemente superiores a los hallazgos de [Boumhidi and Marghich \(2025\)](#), [Mahesh](#)

Tabla 8: Comparacion con la literatura del estado del arte v2 (§3.4). Las metricas no son directamente comparables (diferentes datasets, definiciones de etiqueta y pre-procesado), pero sitúan nuestro resultado en el rango superior reportado en la literatura. La contribucion marginal del ML sobre la heuristica pura se mide en la Tabla 6.

Trabajo	Modelo	Contexto	Metrica reportada
Boumhidi 2025	XGBoost	PYMES Marruecos	AUC=0.930
Mahesh 2025	XGBoost	PYMES India	Acc=0.927
Yufenyuy 2024	XGBoost	PYMES Africa	Acc=0.934
Dasilas 2024 (SLR)	Ensemble medio	Multipais	F1~0.89
Este trabajo	XGBoost (sw=balanced, depth=8)	PYMES Colombia (SIREM)	F1-macro=0.9972 1

et al. (2025) y Yufenyuy et al. (2024). Cabe la advertencia metodológica de que estas métricas no son directamente comparables: cada estudio utiliza un *dataset* distinto, una definición de etiqueta diferente y procedimientos de pre-procesamiento heterogéneos. Además, la propia construcción de la etiqueta de Fase 2 (consenso $B \equiv C$) hereda el Z-Score y razones financieras también presentes en el espacio de predictores; esta circularidad parcial explica las métricas absolutas elevadas. La verdadera medida de la contribución del ML sobre la heurística pura es el delta +30,8 pp reportado en la Sección 6.1.

6.4. Robustez y estabilidad

Tres pruebas de robustez se aplicaron sobre el modelo XGBoost ganador:

Estabilidad temporal (test 2023 vs. 2024): F1-macro 2023 = 0,9970, 2024 = 0,9973, *gap* −0,03 pp. No se observa *drift* dentro del conjunto de prueba.

Estabilidad sectorial (top 5 sectores CIU): F1-macro entre 0,9958 (comercio, $n = 12\,664$) y 0,9980 (inmobiliario, $n = 8\,579$); *gap* máximo-mínimo de 0,22 pp. La Figura 15 grafica esta estabilidad. Ningún sector presenta degradación de desempeño.




Figura 15: Estabilidad de F1-macro por sector CIU sobre el conjunto de test (top 5 sectores). Gap máximo-mínimo = 0,22 pp.

Estabilidad SHAP sobre cinco semillas aleatorias {7, 21, 42, 100, 2024} con los hiperparámetros ganadores: el *Jaccard* promedio del top-10 sobre los 10 pares es 0,927 (mínimo 0,818). Los **tres *features* principales** (Z' -Score, *razon_corriente*, *margen_neto*) están presentes en el **100 %** de las cinco semillas. Esta estabilidad satisface el criterio $\geq 90 \%$ del plan y es consistente con [Lin and Wang \(2024\)](#), quien reporta que las explicaciones SHAP son confiables para las variables de mayor importancia. La Figura 16 muestra la frecuencia de aparición de cada *feature* en el top-10 a través de las cinco semillas.




Figura 16: Estabilidad del top-10 SHAP sobre cinco semillas aleatorias {7, 21, 42, 100, 2024}. Top-3 estable al 100%; *Jaccard* promedio = 0,927.

6.5. Limitaciones

Cuatro limitaciones merecen reconocimiento explícito:

(1) Sesgo de selección del SIREM. El SIREM cubre las PYMES vigiladas por la Superintendencia de Sociedades, segmento más formalizado del universo PYME colombiano. Microempresas, empresas informales y firmas en deterioro avanzado que dejan de reportar antes de la quiebra formal están subrepresentadas. Las conclusiones del modelo se acotan explícitamente al segmento de PYMES con capacidad de reporte NIIF consolidada.

(2) Etiqueta como *proxy* no como ground truth real de quiebra. En ausencia de un registro universal de eventos reales para 38 245 PYMES, la etiqueta es una construcción triangulada. El modelo predice *probabilidad de clasificación en zonas de riesgo definidas por indicadores contables*, no *probabilidad de quiebra real*.

(3) Anomalía 2017 y exclusión del entrenamiento nacional. El año fiscal 2017 presenta 99,1 % de Z-Score nulos en el SIREM nacional, atribuible a un error de captura del concepto contable en la taxonomía de ese año. La exclusión de 2017 del split nacional es defendible pero implica que el modelo no aprende patrones específicos de ese año. En contraste, las 31 observaciones de Ibagué en 2017 se preservaron por mejor calidad regional de reporte.

(4) Dominancia del Z''-Score en el SHAP. El feature `z_score_altman` pesa aproximadamente $3\times$ más que el segundo, lo cual refleja que el etiquetado de Fase 2 (consenso $B \equiv C$) utiliza directamente este score como una de las dos señales. Esta circularidad parcial es metodológicamente honesta pero infla las métricas absolutas; la comparación contra Altman puro (Sección 6.1) cuantifica la verdadera contribución marginal del ML.

7. Conclusiones

A continuación se mapea cada objetivo específico (Sección 1.4) al resultado obtenido y a la limitación principal identificada.

Objetivo 1 — Cálculo de los 18 indicadores financieros. *Cumplido.* El `dataset colombia_indicadores` ($203\,104 \times 23$) contiene los 18 indicadores más el Z''-Score con completitud entre 54,8 % y 95,2 % (Figura 1). Limitación: `dias_inventario` y `rotacion_inventarios` tienen mayor proporción de nulos por la naturaleza de empresas con inventario despreciable.

Objetivo 2 — Etiqueta triangulada. *Cumplido.* La etiqueta final por consenso $B \equiv C$ alcanza Cohen $\kappa_{B,C} = 0,446$ (acuerdo moderado, sobre el umbral 0,4) con distribución 16,8 %

/ 66,4 % / 16,8 %. Limitación: el año 2020 no exhibe el deterioro hipotetizado por COVID, una observación empírica documentada en la Sección 4.2.

Objetivo 3 — Comparación de tres modelos. *Cumplido*, ampliado a cuatro (LR, RF, XGBoost, XGBoost+SMOTE). XGBoost (*sample_weight*) resultó el mejor en validación (F1-macro = 0,9979) y test (F1-macro = 0,9972), superando al *baseline* logístico por +19,9 pp en validación (Tabla 3, Tabla 4).

Objetivo 4 — Evaluación robusta y validación temporal estricta. *Cumplido*. Las métricas de test son F1-macro = 0,9972, AUC-ROC OvR macro = 0,99999, AUC-PR macro = 0,99997. El split temporal 2016–2021 / 2022 / 2023–2024 con *holdout* regional Ibagué fue verificado mediante cuatro *asserts* de no-fuga; sin *drift* entre splits (*gap* |train–test| = 0,28 pp).

Objetivo 5 — Interpretación TreeSHAP global y local. *Cumplido*. El SHAP *beeswarm* (Figura 9) y el ranking de $\text{mean}(|\text{SHAP}|)$ (Figura 10) identifican al Z''-Score, el margen neto, la razón corriente, la cobertura de intereses y la razón de deuda como las *features* dominantes; consistentes con la literatura del estado del arte. Nueve *waterfalls* locales (Figura 11) ejemplifican la decisión caso por caso. Limitación: el Z''-Score pesa aproximadamente 3× más que el segundo *feature*, lo cual refleja la circularidad parcial inherente a la construcción del etiquetado de Fase 2.

Objetivo 6 — Validación en Ibagué. *Cumplido*. F1-macro Ibagué = 0,9948 (sin 2017) con *gap* de +0,24 pp respecto al test nacional, muy por debajo del umbral ≤ 10 pp del criterio de aceptación. Solo un error de clasificación en 359 predicciones, justificado por una caída del 95 % en la cobertura de intereses interanual no observada por la heurística de etiquetado nivel-base. Limitación: la muestra de 61 PYMES es limitada estadísticamente para conclusiones sobre subgrupos sectoriales o departamentales más finos.

Aportes principales. (i) El primer modelo de ML supervisado interpretable aplicado a 38 245 PYMES colombianas bajo NIIF a partir del SIREM, un orden de magnitud superior a los antecedentes en mercados emergentes; (ii) la cuantificación de la contribución marginal del ML sobre Altman puro (+56 pp en F1-macro), que valida empíricamente la transición de los métodos clásicos al ensamble basado en árboles; (iii) un protocolo de etiquetado triangulado documentado y reproducible que enfrenta la ausencia de *ground truth* de quiebra real; y (iv) un *pipeline* reproducible (notebooks 03–10, código en `src/`, datos en `data/processed/`) listo como base para una eventual interfaz web operativa orientada a PYMES de ciudades intermedias.

Trabajo futuro. Las extensiones naturales incluyen: (i) la integración del modelo en una interfaz web accesible a usuarios no técnicos, fuera del alcance del presente trabajo; (ii) la incorporación de fuentes complementarias (Confecámaras, DIAN) para ampliar la cobertura del segmento microempresarial; (iii) el modelado por horizonte temporal (predicción a 1, 2 y 3 años) siguiendo [Bortolotti and Curi \(2024\)](#); y (iv) la validación contra eventos reales de liquidación registrados por la Superintendencia de Sociedades en un subconjunto con trazabilidad disponible.

Referencias

- Abubakar, A., Mahmoud, I., and Tunga, A. K. (2025). Bibliometric analysis of global research trends in predicting financial distress among small and medium-sized enterprises (SMEs): A systematic review. *Journal of Human Resources and Management Science*, 10(7):77–92. E-ISSN: 3026-8680.
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609.
- Bortolotti, A. and Curi, C. (2024). Predicting financial distress and bankruptcy in small and medium enterprises: Insights from machine learning models. SSRN Electronic Copy, disponible en: <https://ssrn.com/abstract=5236086>.
- Boumhidi, J. and Marghich, A. (2025). A machine learning approach for credit risk assessment of SMEs: Evidence from Morocco. *The Economics and Finance Letters*, 12(4):814–831.
- Bouwmeester, A. (2020). Prediction power of accounting-based bankruptcy prediction models: Evidence from Dutch and Belgian public and large private firms. Master’s thesis, University of Twente, Enschede, Netherlands.
- Bubb, S. (2024). Preparándose para el cambio: Lo que las empresas del mercado medio en Colombia deben saber sobre la nueva actualización de las NIIF para PYMES. Technical report, RSM Colombia.
- Bussmann, N., Giudici, P., Marinelli, D., and Papenbrock, J. (2020). Explainable machine learning in credit risk management. *Computational Economics*, 57:203–216.
- Cardona Zuleta, C. P. and Castro Álvarez, J. F. (2025). Desafíos en la gestión del riesgo financiero en las PYMES: una perspectiva práctica en Medellín. *European Public & Social Innovation Review*, 10:1–19.

- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Cultrera, L. and Brédart, X. (2016). Bankruptcy prediction: The case of Belgian SMEs. *Review of Accounting and Finance*, 15(1):101–119.
- Dasilas, A. and Rigani, A. (2024). Machine learning techniques in bankruptcy prediction: A systematic literature review. *Expert Systems with Applications*, 255:124761.
- Deng, S., Aldrich, C., Liu, X., and Zhang, F. (2024). Explainability in reservoir well-logging evaluation: Comparison of variable importance analysis with Shapley value regression, SHAP and LIME. *IFAC-PapersOnLine*, 58(22):66–71.
- Departamento Administrativo de la Función Pública (2015). Decreto anexo 2 de 2015: Marco técnico normativo para los preparadores de información financiera que conforman el grupo 2 (NIIF para las PYMES). Gobierno de Colombia. Marco regulatorio para reporte financiero de PYMES colombianas bajo NIIF.
- Grice, J. S. and Dugan, M. T. (2003). Re-estimations of the Zmijewski and Ohlson bankruptcy prediction models. *Advances in Accounting*, 20:77–93.
- Higuera-Vargas, R. E. and Contreras-Cáceres, M. E. (2021). Aspectos fundamentales de los riesgos financieros y sus incidencias en Colombia. *Reflexiones Contables*, 4(1):8–20. ISSN: 2665-5543.
- Ioannou, S. and Wójcik, D. (2022). The limits to FinTech unveiled by the financial geography of Latin America. *Geoforum*, 128:57–67.
- Kotaskova, A., Lazanyi, K., Amoah, J., and Belas, J. (2020). Financial risk management in the V4 countries’ SMEs segment. *Investment Management and Financial Innovations*, 17(4):228–240.
- Kristanti, F. T., Salim, D. F., and Ihsan, A. F. (2025). Financial distress prediction in emerging markets by using a machine learning approach for financial sustainability. *Discover Sustainability*, 6:1296.
- Lin, L. and Wang, Y. (2024). SHAP stability in credit risk management: A case study in credit card default model. Working paper.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R.,

- Himmelfarb, J., Bansal, N., and Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67.
- Mahesh, R., Kumari, A., Sharma, D., Sreelakshmi, N., and Ramesh, R. (2025). Predicting financial distress in emerging markets: The case of Indian small enterprises. *Cogent Economics & Finance*, 13(1):2489708.
- Mayorga Lira, S. D., Andrade-Arenas, L., and Cano Lengua, M. A. (2023). Credit risk analysis: Using artificial intelligence in a web application. *International Journal of Engineering Trends and Technology*, 71(1):305–316.
- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131.
- Otsuki, A., Narumi, S., and Kawamura, M. (2022). A study on machine learning prediction model for company bankruptcy using features in time series financial data. *Global Journal of Management and Business Research*, 22(1):1–15.
- Papadouli, V., Houstis, E., and Vavalis, M. (2024). Bankruptcy prediction of Greek small and medium-sized enterprises using imbalance data. *Journal of Advances in Information Technology*, 15(8):956–964.
- Pathi, S. P. and Pothineni, J. S. (2025). Interpretable AI in credit scoring: A comparative survey of SHAP, LIME, and hybrid approaches. *The American Journal of Engineering and Technology*, 7(11):151–155.
- Qiu, W., Rudkin, S., and Dłotko, P. (2020). Refining understanding of corporate failure through a topological data analysis mapping of Altman’s Z-score model. *Expert Systems with Applications*, 156:113475.
- Senaya, G. M. (2025). Mitigating financial risks for entrepreneurs in emerging markets through financial literacy. *World Journal of Advanced Research and Reviews*, 25(1):602–620.
- Sujatha, R., Kavitha, D., Uma Maheswari, B., and Gautham Ajay, K. (2025). Ensemble machine learning models for corporate credit risk prediction: A comparative study. *SN Computer Science*, 6:514.
- Sun, J., Li, H., Fujita, H., Fu, B., and Ai, W. (2020). Class-imbalanced dynamic financial distress prediction based on Adaboost-SVM ensemble combined with SMOTE and time weighting. *Information Fusion*, 54:128–144.

- Wang, X., Brorsson, M., and Kräussl, Z. (2024). Datasets for advanced bankruptcy prediction: A survey and taxonomy. *Expert Systems with Applications*. arXiv preprint: 2411.01928.
- Wu, D., Ma, X., and Olson, D. L. (2022). Financial distress prediction using integrated Z-score and multilayer perceptron neural networks. *Decision Support Systems*, 159:113814.
- Yufenyuy, S. S., Adeniji, S., Elom, E., Kizor-Akaraiwe, S., Bello, A.-W., Kanu, E., Ogunleye, O., Ogutu, J., Obunadike, C., Onih, V., and Obunadike, C. (2024). Machine learning for credit risk analysis across the United States. *World Journal of Advanced Research and Reviews*, 22(2):942–955.
- Zhang, Y. and Zhang, J. (2026). Data assetization, financial distress and diversification: A moderated mediation model. *Finance Research Letters*, 96:109687.
- Zhou, F., Fu, L., Li, Z., and Xu, J. (2022). The recurrence of financial distress: A survival analysis. *International Journal of Forecasting*, 38:1100–1115.
- Zmijewski, M. E. (1984). Methodological issues related to the estimation of financial distress prediction models. *Journal of Accounting Research*, 22:59–82.