

1. Estado del Arte

1.1. Introducción

El presente estado del arte examina la literatura científica relevante para el diseño e implementación de un sistema web de análisis financiero con modelo de *Machine Learning* (ML) orientado a la evaluación de riesgo en pequeñas y medianas empresas (PYMES). Esta revisión se sitúa en la intersección de tres dominios disciplinares: (i) el análisis financiero y la evaluación de riesgo empresarial, (ii) las técnicas de aprendizaje automático aplicadas a la predicción de quiebra y dificultades financieras, y (iii) los sistemas de información web como herramientas de soporte a la toma de decisiones gerenciales. El trabajo se apoya en el dataset SIREM de la Superintendencia de Sociedades de Colombia, con cobertura de **38.245 PYMES** y **203.104 observaciones empresa-año** para el panel 2016–2024 bajo normativa NIIF Pymes Grupo 2, escala que se describe en detalle en la Sección 1.6 y cuyo alcance excede en un orden de magnitud a los antecedentes identificados en mercados emergentes.

Metodología de búsqueda y criterios de selección

La búsqueda sistemática de literatura se realizó en las bases de datos Scopus, IEEE Xplore, ScienceDirect, Google Scholar, SciELO y Redalyc, complementada con repositorios de *working papers* como SSRN y arXiv. El periodo de búsqueda comprende publicaciones entre 2015 y 2025, con inclusión de referencias seminales anteriores —como los modelos de [Altman \(1968\)](#), [Ohlson \(1980\)](#) y [Zmijewski \(1984\)](#)— indispensables para contextualizar la evolución del campo.

Los criterios de inclusión priorizaron: (a) artículos revisados por pares publicados en revistas indexadas; (b) estudios enfocados en PYMES, mercados emergentes o aplicaciones de ML en contextos financieros; (c) trabajos con claridad metodológica en el diseño experimental y reporte de métricas; y (d) cobertura temática de los siete ejes de la revisión. Se excluyeron estudios puramente teóricos sin evidencia empírica, artículos sin acceso al texto completo y trabajos con limitaciones metodológicas sustanciales no declaradas por los autores.

La revisión incorpora adicionalmente fuentes no convencionales (tesis de maestría, *working papers*) cuando aportan evidencia empírica relevante no disponible en literatura revisada por pares; en tales casos, el estatus de la fuente se señala explícitamente en el texto para permitir al lector ponderar su solidez. Las revistas de menor impacto factor se consideraron cuando presentan estudios empíricos originales con datos verificables, pero sus hallazgos se triangulan con evidencia proveniente de revistas de alto impacto siempre que es posible. En total, se seleccionaron 40 documentos primarios y 7 referencias seminales.

Organización

La revisión se organiza en siete ejes temáticos que progresivamente construyen la justificación del presente trabajo: la evaluación de riesgo financiero en PYMES (Sección 1.2), los modelos clásicos de predicción de quiebra (Sección 1.3), el *Machine Learning* aplicado a riesgo financiero (Sección 1.4), los sistemas web para análisis financiero (Sección 1.5), el contexto colombiano y las NIIF (Sección 1.6), la interpretabilidad y AI explicable (Sección 1.7), y el uso de datos de panel y series temporales (Sección 1.8). La sección final integra estos hallazgos en una síntesis crítica que identifica los vacíos de investigación que este trabajo busca abordar (Sección 1.9).

1.2. Evaluación de riesgo financiero en PYMES

1.2.1. Fundamentos conceptuales del riesgo financiero

El riesgo financiero en las PYMES constituye un fenómeno multidimensional que abarca diversas categorías —riesgo de crédito, riesgo de liquidez, riesgo de mercado y riesgo operacional— cuyas interacciones determinan la capacidad de supervivencia empresarial. Siguiendo la distinción introducida por [Bortolotti and Curi \(2024\)](#), el presente trabajo adopta dos nociones operativas diferenciadas: la **dificultad financiera** se entiende como un estado potencialmente reversible de deterioro en los indicadores contables (liquidez, solvencia, rentabilidad) que eleva la probabilidad de incumplimiento sin implicar necesariamente insolvencia legal; la **quiebra** se entiende como el evento irreversible de liquidación o insolvencia formalmente declarada ante la autoridad competente (en Colombia, la Superintendencia de Sociedades bajo la Ley 1116 de 2006). Dado que el SIREM no registra sistemáticamente eventos legales de liquidación para todo el universo de PYMES vigiladas, el sistema propuesto estima probabilidad de pertenencia a zonas de *dificultad financiera* definidas por indicadores contables, no probabilidad de quiebra legal. En el contexto colombiano, [Higuera-Vargas and Contreras-Cáceres \(2021\)](#) presentan una revisión de los aspectos fundamentales de los riesgos financieros y sus incidencias en el país, identificando que la falta de una gestión financiera estructurada en las PYMES amplifica su vulnerabilidad ante fluctuaciones económicas. Esta problemática no es exclusivamente colombiana: [Kotaskova et al. \(2020\)](#), a partir de una encuesta a 1.585 empresarios en los países del Grupo de Visegrado (República Checa, Eslovaquia, Polonia y Hungría), encontraron que si bien los emprendedores perciben el riesgo financiero como parte cotidiana de sus actividades, la intensidad y sofisticación de sus prácticas de gestión varía considerablemente entre países, con los empresarios húngaros mostrando mayor autoconfianza en sus capacidades de gestión de riesgo financiero.

La literatura reciente subraya que el factor diferenciador en mercados emergentes es la

alfabetización financiera de los empresarios. [Senaya \(2025\)](#) demostró, mediante un enfoque de métodos mixtos en múltiples mercados emergentes, que existe una relación positiva significativa entre el nivel de alfabetización financiera de los propietarios de PYMES y la eficiencia en la gestión de riesgos, incluyendo mejor acceso a crédito formal, mayor diversificación de fuentes de financiamiento y mejor administración del flujo de caja. Estos hallazgos, articulados con los de [Kotaskova et al. \(2020\)](#) y [Higuera-Vargas and Contreras-Cáceres \(2021\)](#), configuran un panorama en el que la gestión del riesgo financiero en PYMES es un desafío universal, pero particularmente agudo en economías emergentes donde convergen menor alfabetización financiera, mayor informalidad y menor acceso a herramientas tecnológicas de soporte.

1.2.2. Estado de la investigación en predicción de riesgo para PYMES

A pesar de la importancia reconocida de las PYMES para las economías nacionales, la producción académica sobre predicción de dificultades financieras en este segmento es limitada. [Abubakar et al. \(2025\)](#) realizaron un análisis bibliométrico siguiendo el protocolo PRISMA sobre las tendencias globales de investigación en predicción de dificultades financieras en PYMES durante el período 2014–2024. Su búsqueda en Google Scholar arrojó únicamente 19 artículos que cumplieron los criterios de inclusión, cifra que los propios autores califican en sus conclusiones como “alarmantemente baja” considerando la relevancia económica del sector (juicio atribuido a los autores originales; [Abubakar et al., 2025](#)). El análisis de co-citación y co-ocurrencia de palabras clave reveló que la investigación se concentra en cuatro clústeres temáticos —modelos, adaptación, desafíos y oportunidades— con notables vacíos en regiones como África y América Latina.

La dimensión práctica de esta brecha investigativa fue evidenciada por [Cardona Zuleta and Castro Álvarez \(2025\)](#) en un estudio cualitativo con directivos de PYMES en Medellín, Colombia. Mediante entrevistas semiestructuradas, los autores encontraron que una proporción significativa de empresarios desconoce el concepto mismo de riesgo financiero y sus posibles consecuencias, y que la mayoría no aplica estrategias preventivas para afrontarlo. Este hallazgo es particularmente relevante para el presente trabajo, pues revela que el vacío no es solo académico sino profundamente práctico: las PYMES colombianas carecen tanto de modelos predictivos adaptados a su contexto como de herramientas accesibles que traduzcan dichos modelos en información útil para la toma de decisiones.

En síntesis, la literatura sobre riesgo financiero en PYMES evidencia tres vacíos interconectados: (1) la producción investigativa global es cuantitativamente escasa, especialmente para América Latina ([Abubakar et al., 2025](#)); (2) existe una desconexión entre la disponibilidad de datos financieros estandarizados y su aprovechamiento analítico ([Higuera-Vargas](#)

and Contreras-Cáceres, 2021); y (3) los empresarios carecen de cultura financiera y herramientas tecnológicas para gestionar proactivamente el riesgo (Cardona Zuleta and Castro Álvarez, 2025; Senaya, 2025). El presente trabajo busca abordar simultáneamente estas tres dimensiones mediante un sistema web que integre modelos predictivos con visualizaciones interpretables.

Dado que la evaluación de riesgo financiero requiere modelos cuantitativos, la siguiente sección examina los modelos estadísticos clásicos que han servido como referencia durante más de cinco décadas.

1.3. Modelos clásicos de predicción de quiebra

1.3.1. Los modelos fundacionales

La predicción de quiebra empresarial como campo de investigación cuantitativa tiene su origen en el trabajo seminal de Altman (1968), quien desarrolló el modelo Z-Score mediante análisis discriminante múltiple (MDA) utilizando cinco razones financieras —capital de trabajo/activos totales, utilidades retenidas/activos totales, EBIT/activos totales, valor de mercado del patrimonio/valor en libros de la deuda total, y ventas/activos totales— para clasificar empresas en zonas de riesgo (segura, gris e insolvente). Este modelo, originalmente calibrado con empresas manufactureras estadounidenses, estableció el paradigma de que las razones financieras contienen información predictiva sobre la quiebra futura. Altman desarrolló posteriormente variantes para ampliar la aplicabilidad del modelo: el **Z'-Score** para empresas no manufactureras (reemplazando el cociente de valor de mercado por valor en libros del patrimonio) y el **Z''-Score** para mercados emergentes (eliminando además la razón de rotación de activos). Dado que el presente trabajo analiza PYMES colombianas no cotizadas bajo NIIF, la variante conceptualmente adecuada como heurística de etiquetado es el Z''-Score para mercados emergentes, calibrado originalmente con empresas mexicanas.

Doce años después del trabajo original, Ohlson (1980) propuso el O-Score como alternativa, empleando regresión logística con nueve variables que incorporan tamaño de firma, apalancamiento, liquidez y métricas de desempeño. A diferencia del MDA, la regresión logística no requiere supuestos de normalidad multivariada ni igualdad de matrices de covarianza, representando un avance metodológico significativo. Complementariamente, Zmijewski (1984) desarrolló el X-Score mediante regresión probit con solo tres variables —rentabilidad (ingreso neto/activos totales), apalancamiento (deuda total/activos totales) y liquidez (activos corrientes/pasivos corrientes)— demostrando que un modelo parsimonioso puede alcanzar precisión competitiva.

La validez de las categorías de indicadores subyacentes a estos modelos clásicos fue con-

firmada empíricamente por [Cultrera and Brédart \(2016\)](#) en un estudio con 7.152 PYMES belgas (3.576 en quiebra, 3.576 solventes). Mediante regresión logit, los autores encontraron que las razones de rentabilidad y liquidez son los mejores predictores de quiebra para PYMES, validando la selección de indicadores utilizada en el presente trabajo. No obstante, su estudio también reveló que los efectos regionales y de tamaño de firma son significativos, sugiriendo que modelos genéricos no capturan completamente las particularidades del segmento PYMES.

1.3.2. Degradación temporal y limitaciones de transferencia

Un hallazgo crítico de la literatura reciente es que los coeficientes de los modelos clásicos no son estacionarios. [Grice and Dugan \(2003\)](#) demostraron que al aplicar los coeficientes originales de [Ohlson \(1980\)](#) a datos del período 1988–1999, la precisión de clasificación cayó de 98 % a apenas 34,8 %¹, mientras que el modelo de [Zmijewski \(1984\)](#) descendió de 82–96 % a 77,6 %. Los autores atribuyen esta degradación a cambios en el entorno económico —ciclos de negocios, estrategias corporativas, innovación tecnológica y competencia de mercado— que alteran las relaciones entre razones financieras y quiebra. Significativamente, la re-estimación de coeficientes con datos contemporáneos mejoró sustancialmente la precisión, confirmando que los modelos requieren actualización periódica para mantener su validez predictiva.

Estos hallazgos fueron corroborados por [Bouwmeester \(2020\)](#) —en una tesis de maestría de la Universidad de Twente, fuente que se cita con la reserva de no haber sido revisada por pares—, quien evaluó los tres modelos clásicos en empresas holandesas y belgas durante dos períodos distintos (2007–2010 y 2012–2015), encontrando que los coeficientes difieren significativamente entre períodos con diferentes condiciones económicas. La conclusión es inequívoca: los modelos clásicos de predicción de quiebra no pueden aplicarse con sus coeficientes originales a nuevos contextos temporales o geográficos sin una pérdida sustancial de poder predictivo.

Un enfoque metodológico independiente que refuerza esta conclusión fue desarrollado por [Qiu et al. \(2020\)](#), quienes aplicaron análisis topológico de datos (*Topological Data Analysis*, TDA) mediante el algoritmo Ball Mapper sobre el espacio de cinco dimensiones definido por los predictores del modelo de Altman en empresas estadounidenses. Su hallazgo central —que las firmas en quiebra no se concentran en regiones claramente separables del espacio de razones Z-Score, sino que se distribuyen en múltiples subregiones heterogéneas— cuestiona el supuesto fundamental de que una combinación lineal de estos cinco predictores sea

¹La cifra del 34,8 % corresponde específicamente a la tasa de clasificación correcta de empresas efectivamente en quiebra (sensibilidad o *recall* de la clase positiva) bajo los coeficientes originales de Ohlson re-aplicados al período 1988–1999, no al accuracy global del modelo. La reducción refleja la pérdida de poder discriminativo sobre la clase de interés cuando los coeficientes no se re-estiman con datos contemporáneos.

suficiente para discriminar riesgo. Este resultado tiene implicaciones directas para cualquier uso contemporáneo del Z-Score como instrumento clasificador y fundamenta la necesidad de técnicas capaces de capturar no linealidades y agrupaciones topológicas complejas.

Ante estas limitaciones, investigaciones recientes han explorado la superioridad de enfoques de ML. Papadouli et al. (2024) evaluaron tanto modelos clásicos (Z-Score de Altman, S-Score de Springate, modelo de Taffler) como clasificadores de ML (regresión logística, Naive Bayes, ANN, SVM, Random Forest, XGBoost, AutoML) en un dataset de 170 PYMES griegas en quiebra y 1.424 solventes. Los resultados mostraron que el Z-Score clasificó correctamente solo el 66 % de las empresas en quiebra con una tasa de falsos positivos del 36 %, mientras que los métodos de ML —particularmente el aprendizaje semi-supervisado y la transferencia de aprendizaje— lograron desempeños consistentemente superiores, especialmente en el manejo de datos desbalanceados (ratio 1:8 entre quiebra y solvencia).

Tabla 1: Comparación de modelos clásicos de predicción de quiebra

Autor(es)	País Año	Mues- tra	Segmento	Método	Precisión	Limitación
Altman	EE.UU. 1968	66	Manufact.	MDA (Z)	95 % orig.	Manufactureras
Ohlson	EE.UU. 1980	2.163	Cotizadas	Logit	96,1 % orig.	No estacionario
Zmijewski	EE.UU. 1984	840	Cotizadas	Probit	82–96 %	Sesgo muestral
Cultrera y Brédart	Bélgica 2016	7.152	PYMES	Logit	Satisfact.	Solo Bélgica
Grice y Dugan	EE.UU. 2003	~1.050	General	Re-estim.	34,8 % (Ohl.)	Coef. inestab.
Bouwmeester	P. Bajos 2020	Varios	Grandes priv.	Tres modelos	Variable	Coef. inestab.
Qiu et al.	EE.UU. 2020	Varios	General	TDA Ball Map.	Cualitativa	Subreg. heterog.
Papadouli et al.	Grecia 2024	1.594	PYMES	Clás. + ML	66 % (Z)	Desbalanceados

1.3.3. El Z-Score como heurística de etiquetado: riesgos y mitigaciones

La evidencia de Grice and Dugan (2003), Bouwmeester (2020) y Qiu et al. (2020) demuestra que los coeficientes del Z-Score no son estacionarios ni transferibles sin pérdida de poder predictivo, limitación que cobra especial relevancia en el presente trabajo dado que el Z"-Score se utiliza como heurística para generar etiquetas iniciales de riesgo sobre las PYMES colombianas en ausencia de un registro sistemático de eventos reales de quiebra para todo el universo del SIREM. Este uso metodológico exige discutir explícitamente tres riesgos y sus respectivas mitigaciones.

Primer riesgo: el modelo de ML podría limitarse a replicar la clasificación del

Z-Score en lugar de predecir dificultades financieras reales. Este riesgo es inherente al aprendizaje supervisado cuando las etiquetas provienen de una regla heurística observable: si el modelo recibe como predictores las mismas razones financieras que determinan la etiqueta, aprenderá el mapeo heurístico y no añadirá valor predictivo. La mitigación adoptada se articula en cuatro elementos: (i) utilizar un espacio de predictores considerablemente más amplio que las cinco razones del Z-Score —incluyendo 18 indicadores financieros cubriendo liquidez, solvencia, rentabilidad y actividad, junto con variables temporales derivadas como variaciones interanuales y tasas de crecimiento—, lo que rompe la identidad entre predictores y generadores de etiqueta; (ii) emplear umbrales de Z"-Score calibrados al contexto colombiano mediante análisis de la distribución empírica, no los umbrales originales de Altman; (iii) triangular la etiqueta con reglas heurísticas adicionales basadas en señales observables (patrimonio negativo sostenido, pérdidas acumuladas, deterioro consecutivo) para reducir la dependencia de un único criterio; y (iv) validar el modelo final contra eventos reales de liquidación registrados por la Superintendencia de Sociedades en un subconjunto de empresas con trazabilidad disponible.

Segundo riesgo: los coeficientes del Z"-Score originales podrían ser inadecuados para el contexto sectorial colombiano. La mitigación consiste en utilizar el Z"-Score para generar etiquetas categóricas (“riesgo alto”, “riesgo medio”, “riesgo bajo”) mediante zonas calibradas por cuartiles empíricos del dataset, no para producir un puntaje continuo que se asuma preciso. La pregunta que el modelo responde no es “*cuál es el Z-Score*” sino “*cuál es la probabilidad de que una empresa pertenezca al cuartil de riesgo alto*”, una tarea en la que el ruido del Z-Score como proxy se promedia sobre la distribución.

Tercer riesgo: el espacio geométrico del Z-Score no separa limpiamente quiebras y no-quiebras, como evidenciaron [Qiu et al. \(2020\)](#) mediante análisis topológico. Este resultado justifica precisamente la arquitectura metodológica adoptada: utilizar técnicas de ML no lineales (XGBoost) capaces de capturar las subregiones heterogéneas del espacio de riesgo y complementar la predicción con explicaciones SHAP que revelen qué combinaciones de características determinan cada clasificación. El enfoque híbrido del presente trabajo —Z"-Score como insumo de etiquetado junto con 18 indicadores como predictores y XGBoost como modelo— coincide conceptualmente con la arquitectura híbrida validada por [Wu et al. \(2022\)](#), quienes combinaron Z-Score y redes neuronales MLP en empresas chinas y reportaron un 99,40 % de precisión, superior al 86,54 % del Z-Score aislado y al 98,26 % de la red neuronal pura. Este trabajo demuestra que la información del Z-Score, cuando se integra con modelos de ML en lugar de sustituirse por ellos, aporta valor predictivo incremental.

La justificación final del uso del Z"-Score como heurística de etiquetado en este trabajo es pragmática: en ausencia de un registro universal de eventos reales de dificultad financiera

para las 38.245 PYMES del SIREM, una heurística validada parcialmente mediante triangulación constituye una aproximación aceptable para un ejercicio de prueba de concepto, con la advertencia explícita de que las conclusiones del sistema deben interpretarse como “probabilidad de clasificación en zonas de riesgo definidas por indicadores contables” y no como “probabilidad de quiebra real”.

Validación empírica posterior. Los resultados experimentales del presente trabajo (sobre el conjunto de prueba 2023–2024 con 50.957 observaciones empresa-año, ver Sección 1.8.3) corroboran la efectividad de la primera mitigación declarada. Comparando el desempeño del modelo XGBoost contra los dos clasificadores Altman puros sobre las mismas observaciones, se obtiene un F1-macro de 0,997 para XGBoost frente a 0,689 al aplicar el Z”-Score con umbrales empíricos calibrados por terciles del dataset y 0,437 al aplicar los umbrales originales 1,1/2,6 de Altman para mercados emergentes. Los gaps de +30,8 pp (vs. Altman terciles) y +56,0 pp (vs. Altman original) demuestran que el modelo aprende un mapeo no trivial sobre el espacio extendido de 71 características que va más allá de reproducir la regla de etiquetado heurística, confirmando que los predictores adicionales aportan valor predictivo incremental sobre el Z”-Score aislado, en línea con los hallazgos híbridos de [Wu et al. \(2022\)](#).

En conjunto, la evidencia presentada en esta sección permite concluir que los modelos clásicos constituyen una base teórica valiosa —particularmente en la identificación de las categorías de indicadores financieros relevantes— pero resultan insuficientes como predictores autónomos en contextos contemporáneos diferentes al de su calibración original. Las limitaciones de los modelos clásicos han motivado la adopción de técnicas de *Machine Learning*, que no dependen de supuestos distribucionales y pueden capturar relaciones no lineales en los datos financieros. La siguiente sección examina esta corriente de investigación, que constituye el núcleo metodológico del presente trabajo.

1.4. *Machine Learning* aplicado a la predicción de riesgo financiero

1.4.1. Panorama general y revisiones sistemáticas

La aplicación de técnicas de *Machine Learning* a la predicción de riesgo financiero ha experimentado un crecimiento exponencial en la última década. [Dasilas and Rigani \(2024\)](#) realizaron la revisión sistemática más completa identificada en esta búsqueda, analizando 207 estudios empíricos publicados entre 2012 y mediados de 2023 bajo el protocolo PRISMA. Sus hallazgos revelan tres tendencias fundamentales: (1) las redes neuronales son el método de ML más frecuentemente utilizado en términos absolutos; (2) entre los métodos de ensamblado, *Extreme Gradient Boosting* (XGBoost) domina con presencia en 25 de 48 estudios de

ensamble; y (3) XGBoost alcanza un AUC promedio de 89 %, representando una mejora de 6,42 puntos porcentuales sobre los clasificadores individuales. Estos resultados posicionan a XGBoost como el estado del arte de facto para la predicción de quiebra con datos tabulares.

Complementariamente, Paz et al. (2025) condujeron una revisión sistemática de 23 estudios empíricos (2019–2023) enfocados específicamente en la evaluación de riesgo crediticio individual, identificando que la selección de características (*feature selection*) mediante metaheurísticas —algoritmos genéticos, optimización por enjambre de partículas, algoritmo de luciérnagas— representa una tendencia creciente que mejora significativamente el desempeño de los clasificadores. La distribución geográfica de los estudios revisados (China: 9, India: 5, España: 2) confirma la concentración de la investigación en mercados asiáticos, con escasa representación de América Latina.

Desde una perspectiva institucional, el Fondo Monetario Internacional reconoció formalmente el potencial del ML en la evaluación de riesgo crediticio. Bazarbash (2019), en un *working paper* del FMI, analizó las fortalezas y debilidades de las aplicaciones de ML en el contexto de la inclusión financiera, concluyendo que estas técnicas hacen económicamente viable la evaluación de riesgo de pequeños prestatarios al capturar no linealidades y endurecer información blanda. No obstante, el autor advirtió sobre riesgos de exclusión financiera digital, problemas de privacidad de datos y la naturaleza de “caja negra” de los modelos complejos —preocupaciones que justifican la incorporación de técnicas de interpretabilidad en el presente trabajo.

1.4.2. Evidencia empírica: modelos de ensamble en datos financieros de PYMES

La superioridad de los modelos de ensamble sobre los métodos estadísticos clásicos ha sido demostrada consistentemente en estudios empíricos con PYMES de diversas geografías. Dos corrientes principales emergen de la literatura: los estudios que comparan múltiples algoritmos y los que se enfocan en la aplicabilidad a mercados emergentes.

En la primera corriente, Boumhidi and Marghich (2025) evaluaron regresión logística, Random Forest y XGBoost para la evaluación de riesgo crediticio de 124 PYMES marroquíes, utilizando variables financieras, comportamentales y transaccionales. XGBoost demostró la mayor capacidad de detección de incumplimientos, con cero falsos negativos en el conjunto de prueba, lo que lo hace idóneo para contextos donde minimizar la pérdida es prioritario. Random Forest, por su parte, alcanzó el mayor poder de discriminación ($AUC = 0,93$), ofreciendo un balance entre precisión y robustez. Yufenyuy et al. (2024) reportaron resultados similares con datos estadounidenses (32.581 observaciones): Random Forest alcanzó 93,2 % de precisión y Gradient Boosting 93,4 %, con el porcentaje de ingreso destinado al pago de préstamos, el ingreso del prestatario y las tasas de interés como las características más

importantes.

La segunda corriente, enfocada en mercados emergentes, aporta evidencia especialmente relevante para el presente trabajo. [Mahesh et al. \(2025\)](#) desarrollaron modelos predictivos para 547 pequeñas empresas indias con 7.457 observaciones empresa-año (2008–2022), integrando razones financieras, variables específicas de firma y variables macroeconómicas. Utilizando el S-Score de Springate como variable dependiente y regresión logit como método de estimación, alcanzaron 92,7 % de precisión. Sus resultados destacan la importancia de incorporar el contexto macroeconómico —crecimiento del PIB, inflación, incertidumbre de política económica— en modelos para mercados emergentes, donde estas variables tienen mayor volatilidad que en economías desarrolladas.

En una línea complementaria, [Ptak-Chmielewska and Matuszyk \(2020\)](#) aplicaron *Random Survival Forests* (RSF) a 806 empresas polacas (312 en quiebra), comparando con regresión de Cox. El RSF logró una tasa de error de 21,46 % frente al 32 % de Cox, demostrando que los métodos de ML no solo son superiores en clasificación sino también en modelado de tiempo hasta el evento. Un hallazgo adicional relevante es que la inclusión de factores no financieros —sector, forma jurídica, tamaño de empleo, localización— mejoró marginalmente el desempeño (0,65 puntos porcentuales), sugiriendo que las variables financieras contienen la mayor parte de la información predictiva pero los factores contextuales añaden valor.

[Bortolotti and Curi \(2024\)](#) —cuyo trabajo se cita en su versión como *working paper* en SSRN, pendiente de revisión por pares— aportaron una distinción metodológica valiosa al comparar la predicción de dificultad financiera (evento reversible) con la de quiebra (evento irreversible) en PYMES italianas. Utilizando Random Forest, XGBoost y AdaBoost con más de 80 variables financieras, macroeconómicas, geográficas y sectoriales, demostraron que la predicción de quiebra se mantiene estable hasta tres años antes del evento, mientras que la predicción de dificultad financiera pierde precisión en el mediano plazo. Este hallazgo tiene implicaciones directas para el horizonte temporal de predicción del sistema propuesto.

Aportación empírica del presente trabajo. La aplicación de XGBoost (`max_depth=8`, `learning_rate=0,1`, `subsample=0,8`, `colsample_bytree=1,0`, ponderación por clase nativa, `early_stopping_rounds=30`) sobre el panel SIREM consolidado (135.400 observaciones empresa-año para train/val/test, 71 características tras ingeniería) reportó F1-macro de 0,997 y AUC-ROC OvR macro $\approx 1,0$ sobre el conjunto de prueba 2023–2024 (50.957 observaciones), con un *gap* train→test menor a 0,3 pp que indica ausencia de sobreajuste detectable. Estos valores se sitúan en el rango superior reportado en mercados emergentes, comparables o levemente superiores a los hallazgos de [Boumhidi and Marghich \(2025\)](#) sobre PYMES marroquíes (AUC = 0,93), [Mahesh et al. \(2025\)](#) sobre PYMES indias (precisión = 92,7 %) y [Yufenyuy et al. \(2024\)](#) sobre datos estadounidenses (precisión = 93,4 %). Además, la validación sobre el holdout regional de

Ibagué (61 NITs, 359 observaciones empresa-año entre 2016 y 2024) reprodujo el desempeño nacional con $F1\text{-macro} = 0,995$ y un solo error de clasificación, confirmando ausencia de sesgo regional pese a que las empresas ibaguereñas no participaron en el entrenamiento. Las métricas absolutas elevadas reflejan, en parte, que el ground truth incorpora el Z"-Score y razones financieras también presentes en el espacio de predictores; la contribución marginal del ML sobre la heurística pura se cuantifica directamente en la Sección 1.3.3.

1.4.3. Selección entre XGBoost, LightGBM y CatBoost

La literatura reciente ha mostrado que el dominio de XGBoost en predicción financiera (Dasilas and Rigani, 2024) no implica superioridad absoluta sobre sus dos principales competidores dentro de la familia de *gradient boosted decision trees*: LightGBM (Microsoft, 2017) y CatBoost (Yandex, 2018). Una comparación empírica directa de los tres algoritmos en el contexto de riesgo crediticio corporativo fue realizada por Sujatha et al. (2025), quienes evaluaron XGBoost, CatBoost, LightGBM y LSTM sobre un dataset indio de 410 empresas (212 sin incumplimiento, 198 con incumplimiento) rated por ACUITE y BRICKWORK entre 2016 y 2024, utilizando 27 variables explicativas y dos estrategias de reducción dimensional (PCA y selección mediante Random Forest). Sus resultados indican que los tres modelos de ensamble árbol-basados alcanzan desempeños comparables cuando la selección de características se realiza con Random Forest, mientras que LSTM obtiene mejor desempeño bajo reducción con PCA. Las diferencias absolutas entre XGBoost, LightGBM y CatBoost en este estudio son inferiores al 2 % en AUC, consistente con los hallazgos de otras comparativas en la literatura de ML financiero.

La elección de XGBoost en el presente trabajo se justifica sobre tres criterios ponderados: **(1) paridad de desempeño predictivo** —la evidencia (Dasilas and Rigani, 2024; Sujatha et al., 2025) indica que la superioridad cualitativa dentro de la familia GBDT sobre datos tabulares financieros es marginal y dependiente del preprocesamiento, por lo que la elección entre ellos debe basarse en criterios complementarios; **(2) integración con TreeSHAP** —la implementación oficial de TreeSHAP, el método eficiente para calcular valores de Shapley sobre modelos basados en árboles, fue originalmente desarrollada y optimizada para XGBoost (Lundberg et al., 2020), característica decisiva dado que el sistema propuesto debe entregar explicaciones individuales por empresa en tiempo compatible con una interfaz web (Sección 1.7.3); y **(3) madurez del ecosistema** —XGBoost cuenta con documentación, soporte multiplataforma y depuradores de producción más consolidados que LightGBM y CatBoost, factor relevante para un sistema cuya mantenibilidad por terceros (estudiantes, investigadores futuros) es un requisito implícito. LightGBM presenta ventajas de velocidad y consumo de memoria en datasets de escala mayor que el del presente trabajo; CatBoost

destaca en datasets con alta cardinalidad categórica, característica poco prominente en los datos contables del SIREM. En los escenarios donde XGBoost no sea la opción óptima, el presente trabajo contempla la evaluación comparativa experimental de los tres algoritmos durante la fase de selección de modelo.

1.4.4. Desbalance de clases y técnicas de balanceo

El desbalance entre clases constituye uno de los desafíos más persistentes en la predicción de dificultades financieras: las empresas en situación de quiebra representan típicamente una minoría frente a las empresas solventes, con ratios reportados de 1:8 en [Papadouli et al. \(2024\)](#) (PYMES griegas) y de incluso mayor severidad en datasets con cobertura nacional. Un modelo entrenado sobre datos desbalanceados sin mitigación tiende a maximizar la precisión global prediciendo de forma mayoritaria la clase dominante, produciendo alta exactitud agregada pero *recall* muy bajo para la clase de interés (empresas en riesgo).

La técnica más ampliamente utilizada en la literatura para abordar este problema es SMOTE (*Synthetic Minority Over-sampling Technique*), que genera instancias sintéticas de la clase minoritaria mediante interpolación entre vecinos cercanos. [Sun et al. \(2020\)](#) propusieron un marco dinámico integrado de SMOTE con Adaboost-SVM (ADASVM-TW) y ponderación temporal sobre datos de 2.628 empresas chinas cotizadas, demostrando que la integración embebida de SMOTE en el ciclo de iteración del ensamble —generando más muestras sintéticas en regiones difíciles y menos en regiones fáciles— mejora significativamente la capacidad de reconocimiento de la clase minoritaria en comparación con la aplicación simple de SMOTE como preprocesamiento. Este hallazgo es metodológicamente relevante para el presente trabajo porque la aplicación naïve de SMOTE sobre todo el dataset antes de la división entrenamiento/validación/prueba introduce fuga de información (*leakage*) y sobreestima artificialmente el desempeño.

La buena práctica metodológica fue ilustrada por [Kristanti et al. \(2025\)](#), quienes aplicaron SMOTE únicamente dentro de los pliegues de entrenamiento, dejando intactos los conjuntos de validación y prueba, sobre un dataset de 325 empresas indonesias (3.575 observaciones 2013–2023). Su configuración logró F1 de 0,95 en el modelo MLP-ANN y 0,898 en árbol de decisión, confirmando que SMOTE bien aplicado mejora la detección minoritaria sin inflar artificialmente métricas.

Alternativas a SMOTE incluyen: **ADASYN** (*Adaptive Synthetic Sampling*), que pondera la generación de muestras sintéticas según la dificultad de la frontera de decisión local; **submuestreo** (*random undersampling*) de la clase mayoritaria, útil cuando el dataset es grande pero arriesgado por pérdida de información; **ponderación por clase** en la función de pérdida, disponible nativamente en XGBoost mediante el parámetro `scale_pos_weight`;

y **ensembles híbridos** como SMOTE-Boost y EasyEnsemble. La decisión metodológica del presente trabajo será: aplicar SMOTE exclusivamente en los pliegues de entrenamiento con validación cruzada estratificada, comparar contra la alternativa de ponderación por clase nativa de XGBoost, y seleccionar la configuración que maximice F1 y AUC-PR (métricas robustas al desbalance) sobre el conjunto de prueba.

1.4.5. Patrones, limitaciones y vacíos en la literatura de ML

El análisis crítico de los estudios revisados en esta sección revela cuatro patrones sistemáticos que, en conjunto, definen los vacíos que el presente trabajo busca abordar.

Limitación de escala muestral. La mayoría de los estudios empíricos operan con muestras de 124 a 806 empresas (Bortolotti and Curi, 2024; Boumhidi and Marghich, 2025; Ptak-Chmielewska and Matuszyk, 2020). Incluso los estudios más ambiciosos en mercados emergentes, como Mahesh et al. (2025) con 547 empresas y 7.457 observaciones, representan una fracción de lo que estaría disponible con datos administrativos nacionales. Únicamente los estudios con datos de plataformas financieras (Yufenyuy et al., 2024) alcanzan escalas mayores. El presente trabajo, basado en el universo SIREM de PYMES colombianas (Sección 1.6), opera con un orden de magnitud superior a cualquier estudio previo identificado en América Latina sobre predicción de riesgo financiero en PYMES.

Concentración geográfica. La revisión sistemática de Paz et al. (2025) y el análisis bibliométrico de Abubakar et al. (2025) coinciden en que la investigación se concentra en China, Estados Unidos y Europa occidental. América Latina —y Colombia en particular— está severamente subrepresentada, a pesar de contar con fuentes de datos públicas como el SIREM que posibilitarían investigación a gran escala.

Ausencia de integración tecnológica. Ninguno de los ocho estudios revisados en esta sección despliega sus modelos en un sistema web accesible para usuarios finales. La investigación se mantiene en el ámbito experimental —publicaciones académicas con métricas de desempeño— sin traducirse en herramientas útiles para empresarios o analistas financieros.

Sesgo transversal. La mayoría de los estudios utilizan instantáneas de un solo año (*cross-section*) en lugar de datos de panel (múltiples años por empresa). Solo Bortolotti and Curi (2024) y Mahesh et al. (2025) incorporan la dimensión temporal de manera explícita, lo que limita la capacidad de capturar trayectorias de deterioro financiero.

Los resultados reportados en la literatura muestran que los modelos de ensamble alcanzan un AUC promedio de 0,89–0,94 en tareas de predicción de riesgo financiero, con XGBoost como el modelo más frecuentemente reportado como superior (Boumhidi and Marghich, 2025; Chen and Guestrin, 2016; Dasilas and Rigani, 2024). Sin embargo, estos resultados provienen predominantemente de muestras pequeñas en mercados desarrollados o grandes

asiáticos, dejando abierta la pregunta sobre su replicabilidad en el contexto de PYMES colombianas bajo normativa NIIF y con datos de panel a gran escala.

Tabla 2: Comparación de estudios de ML aplicados a riesgo financiero en PYMES

Autor(es)	País Año	N emp.	N obs.	Mejor modelo	AUC / Acc.	Pa- nel	Web
Boumhidi & Marghich	Marruecos 2025	124	—	XGBoost/RF	0,93	No	No
Ptak-Chm. & Matuszyk	Polonia 2020	806	—	RSF	78,5 %	Sí	No
Yufenyuy et al.	EE.UU. 2024	—	32.581	Grad. Boost.	93,4 %	No	No
Dasilas & Rigani (SLR)	Global 2024	—	207 est.	XGBoost	89 % AUC	—	—
Bortolotti & Curi	Italia 2024	—	—	RF/XGBoost	3 años	Sí	No
Mahesh et al.	India 2025	547	7.457	Logit (S-Sc.)	92,7 %	Sí	No
Papadouli et al.	Grecia 2024	1.594	—	AutoML	>66 %	No	No
Paz et al. (SLR)	Global 2025	—	23 est.	Metaheur.	Varia- ble	—	—
Sujatha et al.	India 2025	410	—	XGB/CB/LGBM	≈0,93	No	No
Sun et al.	China 2020	2.628	—	ADASVM-TW	—	Sí	No
Kristanti et al.	Indonesia 2025	325	3.575	MLP+SMOTE	F1=0,95	Sí	No
Este trabajo	Colombia 2026	38.245	203.104	XGB+SHAP	F1=0,997 / AUC≈1,0	Sí	Fu- tu- ro

Si bien los modelos de ML han demostrado alta capacidad predictiva en entornos experimentales, la traducción de estos resultados en herramientas accesibles para los tomadores de decisiones sigue siendo un desafío escasamente abordado. La siguiente sección examina los esfuerzos por integrar modelos analíticos en sistemas web funcionales.

1.5. Sistemas web para análisis financiero

1.5.1. Panorama de herramientas comerciales y académicas

El ecosistema de herramientas analíticas para evaluación financiera de PYMES se estructura en tres capas diferenciadas con volúmenes de investigación académica muy dispares. La

primera capa la constituyen los **bureaus de crédito y plataformas de *scoring* crediticio** —en Colombia, DataCrédito Experian y TransUnion; a nivel regional, Equifax; globalmente, FICO Score y Moody’s Analytics—, que implementan modelos propietarios no documentados en literatura abierta. La segunda capa está compuesta por **plataformas de *business intelligence*** de propósito general (Tableau, Power BI, Qlik, Looker), cuya aplicación al análisis financiero corporativo ha sido ampliamente documentada en literatura gris y manuales técnicos, pero que típicamente operan como capa de visualización sobre modelos analíticos externos, no como sistemas que integren un modelo predictivo propio. La tercera capa la conforman las **plataformas fintech y RegTech** emergentes —en América Latina, Konfio (México), Nubank (Brasil), Addi y Rappi Pay (Colombia)—, que combinan *scoring* basado en ML con interfaces web/móviles dirigidas a usuarios finales. La evidencia académica publicada sobre la arquitectura interna de estas plataformas es escasa por razones competitivas, lo que deja un espacio significativo para investigación académica reproducible sobre la integración de modelos de ML con interfaces web.

El alcance de estas plataformas sobre el tejido PYMES de la región, sin embargo, es limitado. Ioannou and Wójcik (2022), en un análisis cuantitativo y cualitativo de la geografía financiera latinoamericana centrado en Brasil, México y Argentina, demostraron que a pesar del crecimiento acelerado del sector FinTech impulsado por los altos costos de intermediación financiera y políticas de inclusión, la industria continúa operando en los márgenes del sistema financiero global y de los sistemas financieros domésticos, con impacto limitado sobre la inclusión financiera real. Su hallazgo central —que las FinTech no han desafiado sino reforzado la concentración geográfica de los servicios financieros en América Latina, debido a la proximidad de las empresas FinTech a los bancos establecidos, las fuentes de capital y el trabajo calificado— es directamente relevante para el presente trabajo: las PYMES de ciudades intermedias como Ibagué quedan típicamente fuera del alcance tanto de los bureaus tradicionales (enfocados en *scoring* individual) como de las FinTech metropolitanas (enfocadas en Bogotá, Medellín y Cali). Este vacío geográfico-funcional refuerza la pertinencia de herramientas académicas abiertas, reproducibles y diseñadas específicamente para el segmento PYMES subrepresentado por el mercado comercial.

1.5.2. Marcos de decisión y arquitecturas web con componentes analíticos

La integración de modelos analíticos en sistemas web de soporte a la decisión ha sido explorada en diversos dominios, aunque con escasa presencia en el análisis de riesgo financiero para PYMES. Baumont De Oliveira et al. (2021) propusieron un marco de sistema de soporte a la decisión (DSS) colaborativo para el sector de agricultura vertical, incorporando evaluación de riesgo financiero con técnicas de datos imprecisos y análisis probabilístico. Si

bien su aplicación se dirige a un sector diferente, su arquitectura —que centraliza conocimiento de múltiples fuentes, modelos económicos adaptables y evaluación probabilística de riesgo— establece patrones de diseño relevantes para cualquier DSS financiero.

En un contexto más directamente vinculado al riesgo financiero, [Sholapurapu \(2024\)](#) exploró herramientas basadas en IA para la evaluación de riesgo financiero en la planificación y ejecución de proyectos. Mediante un enfoque de métodos mixtos que incluyó análisis de cinco casos en construcción, TI, petróleo, banca y salud, demostró que XGBoost y LSTM logran un RMSE de 0,85–0,72 millones USD frente a 1,5 millones de la línea base, habilitando el monitoreo de riesgo financiero en tiempo real. No obstante, su enfoque se centra en proyectos de gran escala, no en PYMES.

El estudio más directamente relevante para el presente trabajo es el de [Mayorga Lira et al. \(2023\)](#), quienes desarrollaron una aplicación web para análisis de riesgo crediticio utilizando IA en una cooperativa financiera peruana. Implementada en Python con Pandas y Scikit-learn, la aplicación integra redes neuronales, regresión logística y árboles de decisión para automatizar decisiones de aprobación de crédito. Este trabajo, el único identificado en la revisión académica que combina ML con una interfaz web en el contexto latinoamericano, presenta limitaciones significativas: se restringe a una única cooperativa, utiliza una muestra pequeña y no aborda la escalabilidad a miles de empresas.

1.5.3. El vacío de integración

A pesar de la probada efectividad de los modelos de ML para predicción de riesgo financiero (Sección 1.4) y de la existencia de marcos arquitectónicos para DSS basados en web, la literatura revela una ausencia prácticamente total de sistemas académicos integrados que combinen evaluación de riesgo financiero impulsada por ML con una interfaz web accesible para gerentes de PYMES o analistas financieros, particularmente en el contexto colombiano. Los tres estudios académicos revisados —[Baumont De Oliveira et al. \(2021\)](#) en agricultura vertical, [Sholapurapu \(2024\)](#) en proyectos de gran escala y [Mayorga Lira et al. \(2023\)](#) en una cooperativa individual— junto con la concentración metropolitana del mercado FinTech latinoamericano ([Ioannou and Wójcik, 2022](#)), ilustran que los componentes tecnológicos existen pero no han sido articulados para atender la necesidad específica de las PYMES de ciudades intermedias colombianas.

Alcance del presente trabajo y delimitación respecto al sistema web. El presente trabajo se enfoca exclusivamente en el componente analítico de *Machine Learning*: el diseño, entrenamiento, evaluación y validación de un modelo XGBoost interpretable mediante TreeSHAP entrenado sobre datos SIREM de PYMES colombianas. La integración de este modelo en una interfaz web operativa accesible a usuarios no técnicos se considera **trabajo futuro** y

constituye el alcance natural de un proyecto subsiguiente, en el cual el modelo serializado y el pipeline de inferencia documentados en este informe podrán servir como insumos directos. La separación metodológica obedece a la dimensión de cada problema: la construcción de un modelo predictivo robusto sobre datos contables a escala nacional, con validación temporal estricta y pruebas de estabilidad, requiere un conjunto de garantías reproducibles propias del análisis científico de datos; en cambio, la construcción de un sistema web accesible a usuarios no técnicos involucra requisitos diferenciados (UX, autenticación, persistencia, latencia, despliegue) propios de la ingeniería de software de producto. La revisión de literatura efectuada en esta sección, no obstante, conserva su valor metodológico al documentar el panorama tecnológico que enmarca esa eventual extensión operativa.

La viabilidad de un sistema de análisis financiero para PYMES colombianas depende no solo de la disponibilidad de modelos y tecnología, sino también del marco normativo que rige la información financiera. La siguiente sección examina el contexto regulatorio colombiano y las NIIF.

1.6. Contexto colombiano y Normas Internacionales de Información Financiera (NIIF)

1.6.1. Marco normativo NIIF para PYMES en Colombia

Colombia adoptó las Normas Internacionales de Información Financiera (NIIF) para PYMES mediante el Decreto Anexo 2 de 2015, emitido por el Departamento Administrativo de la Función Pública ([Departamento Administrativo de la Función Pública, 2015](#)). Este decreto establece el marco técnico normativo para los preparadores de información financiera clasificados en el Grupo 2 —que comprende la mayoría de las PYMES colombianas— y contiene 32 secciones que abarcan la presentación de estados financieros, la clasificación y medición de activos, el tratamiento de pasivos y patrimonio, el reconocimiento de ingresos, los instrumentos financieros y temas específicos como arrendamientos, intangibles, contingencias, beneficios a empleados e impuestos. La entrada en vigencia de este marco normativo en 2016 coincide precisamente con el año inicial del dataset SIREM utilizado en el presente trabajo (2016–2024), lo que garantiza que toda la información financiera procesada cumple con estándares contables internacionalmente comparables.

El marco NIIF para PYMES no es estático. [Bubb \(2024\)](#) documentó seis cambios técnicos mayores introducidos por la actualización del IASB con vigencia a partir del 1 de enero de 2025: (1) un modelo de reconocimiento de ingresos en cinco pasos alineado con la NIIF 15; (2) provisionamiento de pérdidas crediticias esperadas (modelo ECL); (3) capitalización de arrendamientos según la NIIF 16; (4) opción de capitalización de costos de desarrollo;

(5) medición a valor razonable de propiedades de inversión; y (6) revelaciones de transición ampliadas. Estos cambios tienen efectos potencialmente materiales sobre los indicadores financieros —ingreso neto, EBITDA, razones de apalancamiento y posiciones tributarias— lo que subraya la importancia de utilizar datos bajo un marco normativo consistente y de considerar posibles rupturas estructurales en los datos financieros post-2025.

1.6.2. Implicaciones para la investigación

La adopción de NIIF para PYMES en Colombia tiene implicaciones significativas para la investigación en predicción de riesgo financiero. En primer lugar, la estandarización contable asegura que los estados financieros reportados al SIREM son comparables entre empresas y entre años, eliminando la heterogeneidad contable que afecta a estudios basados en datos no estandarizados. En segundo lugar, la cobertura del SIREM —que incluye más del 82 % de empresas NIIF Pymes entre todas las que reportan a la Superintendencia de Sociedades— proporciona una representatividad que supera ampliamente la de muestras convenientes utilizadas en la mayoría de los estudios revisados en la Sección 1.4.

Sin embargo, como evidenciaron [Cardona Zuleta and Castro Álvarez \(2025\)](#) en Medellín, la existencia de un marco regulatorio robusto no garantiza su aprovechamiento práctico: muchos directivos de PYMES desconocen el potencial analítico de sus propios estados financieros. Esta brecha entre la disponibilidad de datos estandarizados y su uso efectivo para la toma de decisiones constituye precisamente el espacio que el presente sistema busca ocupar, transformando datos financieros bajo NIIF en evaluaciones de riesgo interpretables y accionables.

Cabe destacar que, entre los estudios de ML revisados en la Sección 1.4, ninguno tematiza explícitamente las NIIF como marco metodológico del dataset empleado. Esta característica posiciona al dataset del presente trabajo como una contribución novedosa al campo.

1.6.3. Sesgo de selección del SIREM y representatividad

La fortaleza metodológica del SIREM —estandarización NIIF, cobertura multi-sectorial, panel de más de nueve años fiscales— conlleva simultáneamente un sesgo de selección que debe reconocerse explícitamente para evitar sobregeneralización de los resultados. Las PYMES reportantes al SIREM son **aquellas vigiladas por la Superintendencia de Sociedades**, condición que se activa al cumplir uno de varios criterios: superar determinados umbrales de activos o ingresos, pertenecer a sectores supervisados, o tener obligaciones específicas de reporte. Este criterio excluye sistemáticamente tres subpoblaciones relevantes: (1) microempresas y empresas informales, que concentran la mayor proporción del empleo PYMES en

Colombia pero no reportan estados financieros bajo NIIF; (2) PYMES formales pero de menor tamaño que no alcanzan los umbrales de vigilancia; y (3) empresas en proceso de cese de actividades que dejan de reportar antes de su liquidación formal.

La consecuencia es que el SIREM representa el **segmento más formalizado y resiliente** del universo PYMES colombiano. Si bien no existen cifras oficiales consolidadas, estimaciones cruzadas a partir de datos del DANE y Confecámaras sugieren que el tejido empresarial colombiano comprende cerca de 1,6 millones de unidades productivas, de las cuales aproximadamente 5 % son PYMES formales de los Grupos 1 y 2 bajo NIIF, y solo una fracción de estas cumple con obligaciones de reporte ante la Superintendencia de Sociedades. El SIREM cubre entonces el estrato superior de las PYMES formales, no el universo total.

Este sesgo tiene dos implicaciones para la generalización de los resultados del presente trabajo. En primer lugar, los patrones predictivos aprendidos por el modelo reflejarán la dinámica de riesgo financiero de PYMES con capacidad de reporte formal consolidada, no necesariamente la dinámica de microempresas o empresas informales, que enfrentan patrones de riesgo cualitativamente distintos (dependencia de informalidad laboral, acceso limitado a crédito formal, volatilidad macro mayor). La traducción operacional del sistema hacia estos segmentos requeriría fuentes de datos complementarias (información tributaria, encuestas DANE, datos de Confecámaras). En segundo lugar, las empresas más vulnerables al riesgo financiero extremo probablemente están subrepresentadas en el SIREM por dos mecanismos: (a) las microempresas quiebran sin haber reportado nunca, y (b) las PYMES en deterioro avanzado tienden a dejar de reportar antes de la quiebra formal, lo que produce “censura izquierda” en los datos de panel.

El análisis empírico de [Zhang and Zhang \(2026\)](#), aunque realizado en firmas chinas, ofrece un argumento analógico relevante: la assetización de datos —la capacidad de una firma de generar, gobernar y explotar datos estructurados— se correlaciona con menor *financial distress* y mayor resiliencia organizacional. En el caso colombiano, la capacidad de reporte NIIF bajo vigilancia de Supersociedades es funcionalmente equivalente a esta capacidad de assetización de datos: las empresas del SIREM son precisamente aquellas con infraestructura contable y gobernanza informacional suficiente, lo que correlaciona sesgo de reporte con resiliencia estructural y refuerza la interpretación de que el SIREM muestrea el segmento más robusto del universo PYMES.

Las mitigaciones adoptadas frente a este sesgo son tres: (1) el sistema propuesto se presenta explícitamente como herramienta para PYMES con reporte NIIF consolidado, no como predictor universal del tejido empresarial colombiano; (2) las conclusiones del modelo se acotan a la población representada, con advertencias claras en la documentación del sistema; y (3) se deja como trabajo futuro la integración con fuentes complementarias (información de

Confecámaras, registros de la DIAN) que permitirían ampliar la cobertura hacia segmentos actualmente no representados.

El uso de modelos de ML en contextos financieros regulados plantea una exigencia adicional: la explicabilidad de las predicciones. La siguiente sección examina las técnicas de IA explicable que permiten interpretar las decisiones de modelos complejos.

1.7. Interpretabilidad y AI explicable (XAI)

1.7.1. La necesidad de explicabilidad en modelos financieros

La adopción de modelos de *Machine Learning* en el sector financiero ha intensificado el debate sobre la tensión entre capacidad predictiva e interpretabilidad. Reguladores financieros a nivel global exigen progresivamente que los modelos utilizados para decisiones crediticias sean explicables, no solo precisos (Bazarbash, 2019). En este contexto, las técnicas de IA explicable (XAI, por *Explainable Artificial Intelligence*) han emergido como un campo de investigación orientado a hacer transparentes las predicciones de modelos complejos sin sacrificar significativamente su desempeño.

Bussmann et al. (2020) demostraron que la interpretabilidad y el desempeño predictivo no son mutuamente excluyentes. En un estudio con 15.045 PYMES del sur de Europa, los autores combinaron valores de Shapley con redes de correlación para agrupar predicciones de un modelo XGBoost ($AUROC = 0,93$, frente a 0,81 de la regresión logística) según similitud en sus explicaciones. Mediante árboles de expansión mínima (MST), lograron segmentar empresas por perfiles de riesgo crediticio similares, proporcionando tanto predicciones precisas como interpretaciones útiles para analistas. Este enfoque es particularmente relevante para el presente trabajo, pues demuestra que XGBoost y valores de Shapley pueden aplicarse exitosamente al análisis de riesgo crediticio de PYMES en contextos europeos.

1.7.2. SHAP, LIME y enfoques híbridos

Entre las técnicas de XAI, SHAP (*SHapley Additive exPlanations*) y LIME (*Local Interpretable Model-agnostic Explanations*) constituyen los dos enfoques dominantes en la literatura de riesgo crediticio. Oyeyemi et al. (2025) integraron ambas técnicas en un marco unificado para evaluación de riesgo crediticio, comparando regresión logística (77,3% de precisión), Random Forest y redes neuronales. Sus resultados revelaron que SHAP y LIME identifican consistentemente el monto del préstamo, la edad del prestatario y la duración del crédito como los factores más influyentes, lo que facilita la comunicación de resultados a tomadores de decisiones no técnicos.

La comparación más rigurosa entre estos enfoques fue realizada por [Pathi and Pothine-ni \(2025\)](#), quienes evaluaron SHAP, LIME y un enfoque híbrido (SHAP para selección de características principales, LIME restringido a las características seleccionadas) sobre datos de LendingClub (2007–2020) con un clasificador Random Forest. Bajo condiciones de datos limpios, SHAP demostró superioridad con una correlación de Spearman de 0,902 y un coeficiente Tau de Kendall de 0,855 respecto a la importancia real de las características. Bajo condiciones de ruido gaussiano ($\sigma = 0, 1$), el enfoque híbrido resultó superior (Spearman: 0,898). LIME, en ambas condiciones, mostró la mayor variabilidad (Spearman: 0,673), lo que cuestiona su fiabilidad para aplicaciones reguladas donde la consistencia de las explicaciones es crítica.

Una preocupación práctica adicional es la estabilidad de las explicaciones SHAP ante variaciones estocásticas del modelo. [Lin and Wang \(2024\)](#) —en un *working paper* no revisado por pares cuyos hallazgos se reportan con la debida cautela— abordaron esta cuestión ejecutando 100 modelos XGBoost idénticos en hiperparámetros pero con diferentes semillas aleatorias sobre datos de incumplimiento de tarjetas de crédito (30.000 cuentas). Sus resultados revelaron que la consistencia de los *rankings* SHAP está correlacionada con el nivel de importancia de la variable: las variables de alta importancia (por ejemplo, límite de crédito, clasificada primera en 96 de 100 modelos) mantienen *rankings* altamente estables, mientras que las variables de baja importancia exhiben mayor variabilidad. Este hallazgo tiene implicaciones prácticas directas: las explicaciones SHAP son confiables precisamente para las variables que más importan en la decisión, lo que refuerza su utilidad para comunicar resultados a usuarios finales.

1.7.3. Complejidad computacional de SHAP y viabilidad de despliegue web

Un aspecto frecuentemente omitido en la literatura de XAI aplicada a sistemas productivos es el costo computacional de las explicaciones. Los valores de Shapley clásicos, calculados exactamente, requieren evaluar $O(2^M)$ coaliciones de características para cada predicción, donde M es el número de variables —costo prohibitivo para datasets con decenas de características y miles de consultas concurrentes. La literatura reciente ha producido dos aproximaciones eficientes con perfiles de rendimiento muy distintos: **KernelSHAP**, un método agnóstico al modelo que aproxima valores de Shapley mediante regresión lineal ponderada sobre un conjunto muestreado de coaliciones, con complejidad que crece con el número de muestras y el tamaño del *background dataset*; y **TreeSHAP** ([Lundberg et al., 2020](#)), un algoritmo especializado para modelos basados en árboles (XGBoost, LightGBM, Random Forest, etc.) que calcula valores de Shapley exactos en tiempo polinómico $O(TLD^2)$, donde T es el número de árboles, L el número de hojas y D la profundidad del árbol.

La comparación empírica realizada por [Deng et al. \(2024\)](#) sobre modelos de Random Forest con datos simulados y reales ilustra la paridad de calidad y la disparidad de costo entre las alternativas: los autores evaluaron Shapley completo, KernelSHAP, TreeSHAP y LIME en términos de su correlación con la importancia real de las variables, encontrando que los cuatro métodos producen rankings globales consistentes (correlación $> 0,94$ con la verdad conocida), mientras que LIME exhibe mayor variabilidad local. Sin embargo, el costo computacional diverge en órdenes de magnitud: Shapley completo es inviable para más de una decena de características, KernelSHAP requiere muestreo intensivo y mantiene costo lineal o superior en el tamaño del dataset de *background*, mientras que TreeSHAP opera en tiempos típicamente inferiores a 100 ms por predicción sobre modelos XGBoost de complejidad moderada.

Para el presente trabajo, con 18 indicadores financieros base extendidos por características temporales derivadas (total estimado de 40–60 variables) y un requisito de respuesta inferior a 2 segundos por consulta en la interfaz web, **TreeSHAP constituye la opción metodológicamente adecuada:** (a) es compatible nativamente con XGBoost, el algoritmo seleccionado (Sección 1.4.3); (b) produce valores exactos (no aproximados) sin supuestos adicionales sobre la distribución de características; (c) ofrece latencia compatible con experiencia de usuario fluida en tiempo real; y (d) permite precomputar explicaciones globales (importancia agregada de variables) en lote y mantenerlas en caché para consultas frecuentes. KernelSHAP se reserva como alternativa de respaldo en caso de que se introduzcan componentes del modelo no compatibles con TreeSHAP (por ejemplo, si se incorpora un predictor basado en redes neuronales para variables textuales), con la advertencia de que las explicaciones KernelSHAP requerirían ejecución asíncrona o precomputación.

1.7.4. Síntesis de la sección

La convergencia de los estudios revisados valida la elección del presente trabajo de combinar XGBoost con TreeSHAP como estrategia que logra simultáneamente alto desempeño predictivo ([Bussmann et al., 2020](#); [Dasilas and Rigani, 2024](#)), explicaciones consistentes con la importancia real de las características ([Pathi and Pothineni, 2025](#)), estabilidad para las variables más relevantes ([Lin and Wang, 2024](#)) y latencia compatible con despliegue web en tiempo real ([Deng et al., 2024](#); [Lundberg et al., 2020](#)). Esta combinación resulta especialmente adecuada para un sistema orientado a PYMES colombianas, donde la confianza del usuario en las predicciones depende fundamentalmente de la capacidad del sistema para explicar *por qué* una empresa es clasificada en determinado nivel de riesgo, y la viabilidad operativa depende de que dichas explicaciones se entreguen sin penalizar la experiencia de uso.

Los estudios revisados hasta este punto trabajan predominantemente con datos de corte transversal. Sin embargo, la evaluación del riesgo financiero se enriquece significativamente cuando se incorpora la dimensión temporal. La siguiente sección examina el uso de datos de panel y series temporales en la predicción financiera.

1.8. Datos de panel y series temporales en predicción financiera

1.8.1. Ventajas del enfoque temporal

La mayoría de los estudios de predicción de quiebra operan con datos de corte transversal —una observación por empresa— lo que impide capturar dinámicas de deterioro financiero progresivo. La importancia de incorporar la dimensión temporal fue demostrada convincentemente por [Zhou et al. \(2022\)](#), quienes aplicaron modelos de supervivencia estratificados a 524 empresas chinas cotizadas que se recuperaron de una primera situación de dificultad financiera. Su hallazgo más relevante es que el 28,33 % de las empresas que superaron una primera crisis experimentaron una recurrencia posterior, y que el tiempo entre recuperación y recurrencia se acelera con cada evento repetido. Este resultado, indetectable con análisis transversal, justifica directamente el uso de datos de panel que permitan rastrear trayectorias financieras a lo largo del tiempo.

[Otsuki et al. \(2022\)](#) contribuyeron a esta línea de investigación desarrollando un modelo de predicción de quiebra basado en características de series temporales financieras para empresas japonesas. Mediante análisis de agrupamiento (*clustering*) temporal, demostraron que los patrones dinámicos en los estados financieros —tendencias de deterioro, puntos de inflexión, velocidad de cambio— contienen información predictiva que complementa la proporcionada por las razones financieras estáticas.

Desde la perspectiva del *deep learning*, [Zhang and Han \(2025\)](#) compararon LSTM (*Long Short-Term Memory*), XGBoost y regresión logística para la construcción de modelos de alerta temprana de riesgo financiero en 1.750 empresas de alta tecnología chinas. El modelo LSTM, diseñado específicamente para capturar dependencias temporales, alcanzó un 97 % de *recall* y un AUC de 0,9908, superando ampliamente a XGBoost (AUC: 0,9477) y regresión logística (AUC: 0,8772). Los autores utilizaron KernelSHAP para interpretar el modelo, identificando la razón deuda-activos como la variable más significativa (valor SHAP: 0,284). Si bien LSTM supera a XGBoost en el aprovechamiento nativo de patrones temporales, cabe señalar que XGBoost puede incorporar características temporales derivadas —variaciones interanuales, promedios móviles, tasas de cambio— sin requerir la complejidad arquitectónica del *deep learning*, una consideración relevante para el presente trabajo donde la interpretabilidad y la simplicidad de despliegue son prioritarias.

1.8.2. Datasets y modalidades de datos para predicción de quiebra

La disponibilidad de datos es un factor crítico que condiciona la investigación en predicción de quiebra. Wang et al. (2024) realizaron una taxonomía y revisión de datasets públicamente disponibles, identificando cinco principales conjuntos de datos gratuitos: el dataset americano (78.682 observaciones firma-año), el polaco (UCI), el taiwanés (6.819 instancias), el SMEsD (3.976 PYMES) y el HAT (13.489 empresas). Los autores clasifican los datos en cinco categorías —contables, de mercado, macroeconómicos, relacionales y no financieros— y documentan que la escasez de datasets válidos y públicos constituye el principal cuello de botella para la investigación avanzada, especialmente para PYMES cuyos datos no están disponibles en bases comerciales como Compustat u Orbis. Notablemente, el SIREM colombiano no figura entre los datasets identificados, lo que posiciona los datos del presente trabajo como una contribución novedosa a la comunidad investigativa.

Exploraciones alternativas al procesamiento de datos tabulares financieros incluyen el trabajo de Dzik-Walczak and Odziemczyk (2021), quienes convirtieron datos tabulares de empresas polacas en representaciones de imágenes en escala de grises mediante simulación de Monte Carlo para aplicar redes neuronales convolucionales (CNN). Si bien las CNN alcanzaron los puntajes AUC-ROC más altos en su comparación, los autores encontraron que los modelos basados en árboles de decisión (Random Forest, XGBoost) son insensibles a las transformaciones de preprocesamiento, una ventaja práctica significativa en contextos de producción donde la complejidad del *pipeline* de datos debe minimizarse.

Finalmente, Mancisidor and Aas (2024), en un *preprint* de arXiv pendiente de revisión por pares, introdujeron modelos generativos multimodales que combinan datos contables, de mercado y textuales (secciones MD&A de reportes anuales) para predicción de quiebra. Su modelo CMMD (*Conditional Multimodal Discriminative*) resuelve una limitación práctica crítica: el 40 % de las empresas carece de datos textuales accesibles, pero el modelo puede ser entrenado con todas las modalidades y predecir utilizando solo datos contables y de mercado. Si bien el presente trabajo no incorpora datos textuales, la amplitud del dataset SIREM —204 variables financieras por observación empresa-año— proporciona un espacio de características rico que, combinado con la ingeniería de características temporales, captura múltiples dimensiones de la situación financiera empresarial.

1.8.3. Validación temporal en predicción con datos de panel

El uso de datos de panel introduce un requisito metodológico frecuentemente ignorado: la estrategia de validación debe respetar la ordenación temporal de las observaciones. La validación cruzada aleatoria clásica —empleada por defecto en muchos estudios de ML financiero—

introduce fuga temporal (*temporal leakage*): si observaciones de la misma empresa en años consecutivos quedan repartidas entre los pliegues de entrenamiento y prueba, el modelo se evaluará con información futura sobre empresas cuyo pasado ya conoce, sobreestimando su desempeño en producción, donde la predicción debe realizarse sobre empresas y años nunca vistos. Este problema ha sido reconocido explícitamente por [Bortolotti and Curi \(2024\)](#), quienes evaluaron la estabilidad temporal de la predicción de quiebra en horizontes de uno, dos y tres años antes del evento, y por [Mahesh et al. \(2025\)](#), quienes usaron un esquema de ventana deslizante en panel 2008–2022 para preservar la cronología.

Las estrategias de validación temporalmente válidas incluyen: **(1) hold-out temporal (*time-based split*)**: entrenar con los primeros k años del panel y evaluar con los últimos, replicando el escenario de producción; **(2) validación cruzada con ventana expansiva**: iterativamente entrenar con años $[1, t]$ y evaluar en año $t+1$, avanzando t en cada pliegue; **(3) validación cruzada con ventana deslizante**: entrenar con años $[t-w, t]$ y evaluar en $t+1$, controlando el ancho de la ventana; y **(4) validación cruzada por empresa**: asegurar que todas las observaciones de una misma empresa residan en el mismo pliegue, aun cuando los pliegues se determinan aleatoriamente, evitando fuga por identidad empresarial. El enfoque adoptado en el presente trabajo combina las estrategias (1) y (4): el modelo se entrena con datos de 2016–2021, se valida con 2022 y se prueba con 2023–2024, manteniendo además la integridad de las trayectorias empresariales dentro de cada partición. Esta configuración replica el escenario realista en el que el sistema debe evaluar empresas en un año fiscal reciente basándose en patrones aprendidos de años anteriores.

La implementación concreta de este esquema sobre el panel SIREM produjo una partición de 108.522 / 26.878 / 50.957 observaciones empresa-año para entrenamiento / validación / prueba respectivamente, con asserts automáticos verificando que ninguno de los 61 NITs identificados como pertenecientes al subconjunto de Ibagué —reservado como *holdout* regional con 359 observaciones, ver Sección 1.6.3— aparece en los splits nacionales. El año fiscal 2017 fue excluido del split nacional por una anomalía documentada en el reporte SIREM (99% de valores nulos en Z-Score y razones derivadas atribuible a un error de captura del concepto contable en la taxonomía de ese año), mientras que en Ibagué las 31 observaciones de 2017 se preservaron por mejor calidad regional de reporte y se utilizaron para diagnóstico. El desempeño del modelo final no exhibió *drift* temporal observable entre los años del conjunto de prueba (F1-macro 2023 = 0,997 vs. 2024 = 0,997, gap inferior a 0,1 pp), respaldando empíricamente la validez de la estrategia de partición cronológica frente al riesgo de degradación temporal documentado por [Grice and Dugan \(2003\)](#) y [Bouwmeester \(2020\)](#).

1.8.4. Implicaciones para la presente investigación

La estructura de panel del dataset utilizado en este trabajo habilita tanto la ingeniería de características temporales (variaciones interanuales de indicadores, promedios móviles, tasas de crecimiento) como el modelado con conciencia temporal y la validación temporalmente válida descrita previamente. Esto atiende directamente al llamado de múltiples autores ([Bortolotti and Curi, 2024](#); [Otsuki et al., 2022](#); [Zhang and Han, 2025](#); [Zhou et al., 2022](#)) que argumentan a favor de enfoques longitudinales en la predicción de dificultades financieras. Adicionalmente, la inclusión del SIREM como fuente de datos —no documentada previamente en la taxonomía de [Wang et al. \(2024\)](#)— constituye una contribución a la infraestructura de datos disponible para la comunidad investigativa.

Tras revisar las siete dimensiones de la literatura relevante, la siguiente sección integra los hallazgos en una síntesis crítica que identifica los vacíos específicos que este trabajo de investigación busca abordar.

1.9. Síntesis crítica y vacíos de investigación

1.9.1. Síntesis de hallazgos principales

La revisión de la literatura a través de siete ejes temáticos permite identificar un conjunto de hallazgos convergentes que configuran el estado actual del conocimiento en la predicción de riesgo financiero para PYMES.

En primer lugar, el riesgo financiero en PYMES es un problema reconocido pero insuficientemente investigado. El análisis bibliométrico de [Abubakar et al. \(2025\)](#) identificó únicamente 19 estudios publicados en una década (2014–2024) específicamente sobre predicción de dificultades financieras en PYMES, mientras que la evidencia cualitativa de [Cardona Zuleta and Castro Álvarez \(2025\)](#) en Medellín reveló que muchos empresarios colombianos desconocen incluso el concepto de riesgo financiero. Esta doble carencia —académica y práctica— establece la pertinencia del presente trabajo.

En segundo lugar, los modelos clásicos de predicción de quiebra, si bien fundamentales en la construcción del campo, presentan una degradación temporal documentada que los inhabilita como predictores autónomos en contextos contemporáneos. La caída de precisión del modelo de [Ohlson \(1980\)](#) del 98 % al 34,8 % reportada por [Grice and Dugan \(2003\)](#), corroborada por [Bouwmeester \(2020\)](#), [Papadouli et al. \(2024\)](#) y el análisis topológico de [Qiu et al. \(2020\)](#), constituye la evidencia más contundente de esta limitación y fundamenta el uso del Z'-Score únicamente como heurística de etiquetado bajo las mitigaciones discutidas en la Sección 1.3.3.

En tercer lugar, las técnicas de *Machine Learning*, particularmente los métodos de ensamble basados en árboles (XGBoost, LightGBM, CatBoost), han demostrado consistentemente superioridad sobre los métodos estadísticos clásicos, con desempeños prácticamente equivalentes entre sí (Sujatha et al., 2025). La revisión de 207 estudios de Dasilas and Rigani (2024) posiciona a XGBoost con un AUC promedio de 89 %, mientras que estudios empíricos individuales reportan precisiones de 92–94 % (Boumhidi and Marghich, 2025; Mahesh et al., 2025; Yufenyuy et al., 2024). El desbalance de clases, inherente a la predicción de dificultades financieras, se aborda efectivamente mediante SMOTE aplicado dentro de los pliegues de entrenamiento (Kristanti et al., 2025; Sun et al., 2020) o mediante ponderación nativa por clase.

En cuarto lugar, la integración de modelos de ML en sistemas web funcionales permanece como un área prácticamente inexplorada en la literatura académica abierta. El único prototipo académico identificado en América Latina (Mayorga Lira et al., 2023) se limita a una cooperativa individual, mientras que las plataformas comerciales fintech de la región (Ioannou and Wójcik, 2022) operan en los márgenes del sistema financiero y concentran su actividad en capitales metropolitanas, dejando desatendido el tejido PYMES de ciudades intermedias. El presente trabajo aborda este vacío de manera parcial al producir un componente ML reproducible y bien documentado; la traducción operativa del modelo en una interfaz web accesible a usuarios no técnicos se reconoce explícitamente como trabajo futuro.

En quinto lugar, las técnicas de XAI —particularmente TreeSHAP— proporcionan explicaciones consistentes, estables, correlacionadas con la importancia real de las características (Bussmann et al., 2020; Lin and Wang, 2024; Pathi and Pothineni, 2025) y computacionalmente viables para despliegue web en tiempo real (Deng et al., 2024; Lundberg et al., 2020), habilitando la comunicación de resultados a usuarios no técnicos sin sacrificar desempeño predictivo ni experiencia de usuario.

Finalmente, la incorporación de la dimensión temporal —mediante datos de panel en lugar de cortes transversales y validación cronológicamente válida— enriquece significativamente la predicción al capturar trayectorias de deterioro y recurrencia de dificultades financieras (Bortolotti and Curi, 2024; Zhang and Han, 2025; Zhou et al., 2022).

1.9.2. Identificación de vacíos

La integración de los hallazgos de las siete secciones precedentes permite identificar seis vacíos específicos en la literatura que el presente trabajo busca abordar (Tabla 3).

Tabla 3: Matriz de vacíos de investigación y contribución del presente trabajo

Dimensión	Cobertura en la literatura	Presente trabajo
Contexto geográfico	Concentración en China, EE.UU. y Europa. América Latina escasamente representada; Colombia solo con estudios cualitativos (Cardona Zuleta and Castro Álvarez, 2025 ; Higuera-Vargas and Contreras-Cáceres, 2021)	PYMES colombianas bajo NIIF Pymes Grupo 2, con cobertura panel 2016–2024
Escala muestral	Típicamente 124–806 empresas (Boumhidi and Marghich, 2025 ; Ptak-Chmielewska and Matuszyk, 2020); máximo 7.457 observaciones en mercados emergentes (Mahesh et al., 2025)	Universo SIREM de PYMES vigiladas por Supersociedades, un orden de magnitud superior a los antecedentes en mercados emergentes
Datos bajo NIIF	Ningún estudio de ML revisado tematiza explícitamente las NIIF como marco metodológico	Dataset completo bajo NIIF Pymes (2016–2024) con advertencia explícita de sesgo de selección (Sección 1.6.3)
Integración web	Solo Mayorga Lira et al. (2023) (una cooperativa peruana); FinTech regional concentrada en capitales (Ioannou and Wójcik, 2022)	Componente ML reproducible y exportable (modelo serializado + pipeline de inferencia con TreeSHAP), base directa para una eventual interfaz web en trabajo futuro orientada a PYMES de ciudades intermedias
Dimensión temporal	Mayoría de estudios transversales; pocos aprovechan datos de panel (Bortolotti and Curi, 2024 ; Mahesh et al., 2025)	Datos de panel de 9 años fiscales con ingeniería de características temporales y validación cronológica estricta (Sección 1.8.3)
Interpretabilidad en contexto LATAM	Estudios de XAI aplicados a crédito en Europa (Bussmann et al., 2020) y Asia, ninguno en PYMES latinoamericanas	XGBoost + TreeSHAP aplicado a PYMES colombianas con latencia compatible con despliegue web

1.9.3. Posicionamiento de la investigación

El presente trabajo se diferencia de los antecedentes en cinco aspectos fundamentales. **Primero**, la escala del dataset —universo de PYMES colombianas vigiladas por la Superintendencia de Sociedades con panel 2016–2024, del orden de decenas de miles de empresas y centenas de miles de observaciones empresa-año— supera en un orden de magnitud a los estudios previos más ambiciosos en mercados emergentes (Mahesh et al., 2025), con reconocimiento explícito del sesgo de selección asociado (Sección 1.6.3). **Segundo**, la utilización de datos bajo normativa NIIF para PYMES garantiza estandarización y comparabilidad que ningún estudio previo de ML en riesgo financiero ha explotado explícitamente. **Tercero**, el enfoque adoptado —modelo de ML reproducible, exportable y documentado en un *pipeline* completo desde la carga del SIREM crudo hasta la inferencia con explicaciones SHAP— aborda una brecha que la literatura identifica pero no resuelve: la disponibilidad de un componente analítico contextualizado a PYMES bajo NIIF, listo para servir de base a herramientas operativas posteriores que la literatura existente no ha provisto (Baumont De Oliveira et al., 2021; Ioannou and Wójcik, 2022; Mayorga Lira et al., 2023); la integración en una interfaz web operativa se identifica como trabajo futuro natural sobre los artefactos producidos. **Cuarto**, la incorporación de TreeSHAP como mecanismo de interpretabilidad, selección justificada tanto por consistencia con la importancia real (Pathi and Pothineni, 2025) como por viabilidad computacional en producción (Deng et al., 2024; Lundberg et al., 2020), responde a la creciente exigencia regulatoria y académica de transparencia en modelos financieros (Bazarbash, 2019; Bussmann et al., 2020). **Quinto**, la estructura de datos de panel con validación cronológicamente válida habilita la captura de dinámicas temporales que los enfoques transversales con validación aleatoria no pueden detectar sin introducir fuga de información (Bortolotti and Curi, 2024; Otsuki et al., 2022; Zhou et al., 2022).

Como se evidencia en la Tabla 2, ningún estudio previo combina simultáneamente un dataset de escala nacional bajo NIIF, un modelo de ML con interpretabilidad TreeSHAP, validación temporal estricta y manejo formal del desbalance de clases para PYMES latino-americanas. Esta convergencia de características define la contribución específica del presente trabajo al cuerpo de conocimiento en predicción de riesgo financiero para PYMES; la integración de los artefactos producidos en una herramienta web operativa queda planteada como trabajo futuro.

En correspondencia con los objetivos específicos del trabajo, cada componente encuentra sustento en la literatura revisada: la selección de indicadores financieros se apoya en los hallazgos de Cultrera and Brédart (2016) y Ptak-Chmielewska and Matuszyk (2020); la elección de XGBoost como algoritmo principal se fundamenta en la evidencia de Dasilas and Rigani (2024), Boumhidi and Marghich (2025), Sujatha et al. (2025) y Chen and Guestrin

(2016); el manejo del desbalance de clases se guía por Sun et al. (2020) y Kristanti et al. (2025); la incorporación de TreeSHAP se justifica por Busmann et al. (2020), Pathi and Pothineni (2025), Lundberg et al. (2020) y Deng et al. (2024); las arquitecturas de eventual integración web —reservadas para trabajo futuro— encuentran referencias en Mayorga Lira et al. (2023) y Baumont De Oliveira et al. (2021); y la validación temporal se sustenta en Bortolotti and Curi (2024) y Mahesh et al. (2025). El estado del arte revisado, por tanto, no solo contextualiza el presente trabajo sino que proporciona la base teórica y empírica para cada decisión metodológica y tecnológica adoptada.

Referencias

- Abubakar, A., Mahmoud, I., and Tunga, A. K. (2025). Bibliometric analysis of global research trends in predicting financial distress among small and medium-sized enterprises (SMEs): A systematic review. *Journal of Human Resources and Management Science*, 10(7):77–92. E-ISSN: 3026-8680.
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4):589–609.
- Baumont De Oliveira, F. J., Ferson, S., and Dyer, R. (2021). A collaborative decision support system framework for vertical farming business developments. *International Journal of Decision Support System Technology*, 13(1):34–46.
- Bazarbash, M. (2019). FinTech in financial inclusion: Machine learning applications in assessing credit risk. IMF Working Paper WP/19/109, International Monetary Fund.
- Bortolotti, A. and Curi, C. (2024). Predicting financial distress and bankruptcy in small and medium enterprises: Insights from machine learning models. SSRN Electronic Copy, disponible en: <https://ssrn.com/abstract=5236086>.
- Boumhidi, J. and Marghich, A. (2025). A machine learning approach for credit risk assessment of SMEs: Evidence from Morocco. *The Economics and Finance Letters*, 12(4):814–831.
- Bouwmeester, A. (2020). Prediction power of accounting-based bankruptcy prediction models: Evidence from Dutch and Belgian public and large private firms. Master’s thesis, University of Twente, Enschede, Netherlands.

- Bubb, S. (2024). Preparándose para el cambio: Lo que las empresas del mercado medio en Colombia deben saber sobre la nueva actualización de las NIIF para PYMES. Technical report, RSM Colombia.
- Bussmann, N., Giudici, P., Marinelli, D., and Papenbrock, J. (2020). Explainable machine learning in credit risk management. *Computational Economics*, 57:203–216.
- Cardona Zuleta, C. P. and Castro Álvarez, J. F. (2025). Desafíos en la gestión del riesgo financiero en las PYMES: una perspectiva práctica en Medellín. *European Public & Social Innovation Review*, 10:1–19.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Cultrera, L. and Brédart, X. (2016). Bankruptcy prediction: The case of Belgian SMEs. *Review of Accounting and Finance*, 15(1):101–119.
- Dasilas, A. and Rigani, A. (2024). Machine learning techniques in bankruptcy prediction: A systematic literature review. *Expert Systems with Applications*, 255:124761.
- Deng, S., Aldrich, C., Liu, X., and Zhang, F. (2024). Explainability in reservoir well-logging evaluation: Comparison of variable importance analysis with Shapley value regression, SHAP and LIME. *IFAC-PapersOnLine*, 58(22):66–71.
- Departamento Administrativo de la Función Pública (2015). Decreto anexo 2 de 2015: Marco técnico normativo para los preparadores de información financiera que conforman el grupo 2 (NIIF para las PYMES). Gobierno de Colombia. Marco regulatorio para reporte financiero de PYMES colombianas bajo NIIF.
- Dzik-Walczak, A. and Odziemczyk, M. (2021). Modelling cross-sectional tabular data using convolutional neural networks: Prediction of corporate bankruptcy in Poland. *Central European Economic Journal*, 8(55):352–377.
- Grice, J. S. and Dugan, M. T. (2003). Re-estimations of the Zmijewski and Ohlson bankruptcy prediction models. *Advances in Accounting*, 20:77–93.
- Higuera-Vargas, R. E. and Contreras-Cáceres, M. E. (2021). Aspectos fundamentales de los riesgos financieros y sus incidencias en Colombia. *Reflexiones Contables*, 4(1):8–20. ISSN: 2665-5543.

- Ioannou, S. and Wójcik, D. (2022). The limits to FinTech unveiled by the financial geography of Latin America. *Geoforum*, 128:57–67.
- Kotaskova, A., Lazanyi, K., Amoah, J., and Belas, J. (2020). Financial risk management in the V4 countries’ SMEs segment. *Investment Management and Financial Innovations*, 17(4):228–240.
- Kristanti, F. T., Salim, D. F., and Ihsan, A. F. (2025). Financial distress prediction in emerging markets by using a machine learning approach for financial sustainability. *Discover Sustainability*, 6:1296.
- Lin, L. and Wang, Y. (2024). SHAP stability in credit risk management: A case study in credit card default model. Working paper.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., and Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67.
- Mahesh, R., Kumari, A., Sharma, D., Sreelakshmi, N., and Ramesh, R. (2025). Predicting financial distress in emerging markets: The case of Indian small enterprises. *Cogent Economics & Finance*, 13(1):2489708.
- Mancisidor, R. A. and Aas, K. (2024). Multimodal generative models for bankruptcy prediction using textual data. arXiv preprint: 2211.08405.
- Mayorga Lira, S. D., Andrade-Arenas, L., and Cano Lengua, M. A. (2023). Credit risk analysis: Using artificial intelligence in a web application. *International Journal of Engineering Trends and Technology*, 71(1):305–316.
- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1):109–131.
- Otsuki, A., Narumi, S., and Kawamura, M. (2022). A study on machine learning prediction model for company bankruptcy using features in time series financial data. *Global Journal of Management and Business Research*, 22(1):1–15.
- Oyeyemi, D. O., Okosieme, O. O., Idowu-Kunlere, O., Julius, E. A., and Nwinyi, I. P. (2025). Explainable AI for credit risk assessment: Integrating machine learning with business analytics. *IOSR Journal of Economics and Finance*, 16(5):63–72. ISSN: 2321-5933.

- Papadouli, V., Houstis, E., and Vavalis, M. (2024). Bankruptcy prediction of Greek small and medium-sized enterprises using imbalance data. *Journal of Advances in Information Technology*, 15(8):956–964.
- Pathi, S. P. and Pothineni, J. S. (2025). Interpretable AI in credit scoring: A comparative survey of SHAP, LIME, and hybrid approaches. *The American Journal of Engineering and Technology*, 7(11):151–155.
- Paz, Á., Crawford, B., Monfroy, E., Barrera-García, J., Peña Fritz, Á., Soto, R., Cisternas-Caneo, F., and Yáñez, A. (2025). Machine learning and metaheuristics approach for individual credit risk assessment: A systematic literature review. *Biomimetics*, 10:326.
- Ptak-Chmielewska, A. and Matuszyk, A. (2020). Application of the random survival forests method in the bankruptcy prediction for small and medium enterprises. *Argumenta Oeconomica*, 44(1):127–144.
- Qiu, W., Rudkin, S., and Dłotko, P. (2020). Refining understanding of corporate failure through a topological data analysis mapping of Altman’s Z-score model. *Expert Systems with Applications*, 156:113475.
- Senaya, G. M. (2025). Mitigating financial risks for entrepreneurs in emerging markets through financial literacy. *World Journal of Advanced Research and Reviews*, 25(1):602–620.
- Sholapurapu, P. K. (2024). AI-based financial risk assessment tools in project planning and execution. *European Economic Letters*, 14(1):1995–2001. ISSN: 2323-5233.
- Sujatha, R., Kavitha, D., Uma Maheswari, B., and Gautham Ajay, K. (2025). Ensemble machine learning models for corporate credit risk prediction: A comparative study. *SN Computer Science*, 6:514.
- Sun, J., Li, H., Fujita, H., Fu, B., and Ai, W. (2020). Class-imbalanced dynamic financial distress prediction based on Adaboost-SVM ensemble combined with SMOTE and time weighting. *Information Fusion*, 54:128–144.
- Wang, X., Brorsson, M., and Kräussl, Z. (2024). Datasets for advanced bankruptcy prediction: A survey and taxonomy. *Expert Systems with Applications*. arXiv preprint: 2411.01928.
- Wu, D., Ma, X., and Olson, D. L. (2022). Financial distress prediction using integrated Z-score and multilayer perceptron neural networks. *Decision Support Systems*, 159:113814.

- Yufenyuy, S. S., Adeniji, S., Elom, E., Kizor-Akaraiwe, S., Bello, A.-W., Kanu, E., Ogunleye, O., Ogutu, J., Obunadike, C., Onih, V., and Obunadike, C. (2024). Machine learning for credit risk analysis across the United States. *World Journal of Advanced Research and Reviews*, 22(2):942–955.
- Zhang, W. and Han, L. (2025). Comparative study on time series deep learning based financial risk early warning model construction for high-tech enterprises. In *Proceedings of the 2025 International Conference on Digital Economy and Information Systems (DEIS 2025)*, pages 328–333, Guangzhou, China.
- Zhang, Y. and Zhang, J. (2026). Data assetization, financial distress and diversification: A moderated mediation model. *Finance Research Letters*, 96:109687.
- Zhou, F., Fu, L., Li, Z., and Xu, J. (2022). The recurrence of financial distress: A survival analysis. *International Journal of Forecasting*, 38:1100–1115.
- Zmijewski, M. E. (1984). Methodological issues related to the estimation of financial distress prediction models. *Journal of Accounting Research*, 22:59–82.